GCV 2026
9° Congresso Brasileiro sobre Gestão do Ciclo de Vida

TESTE DE CONTAMINAÇÃO EM LLMS APLICADOS À ACV REGIONALIZADA DO MATERIAL PARTICULADO EM PRODUÇÃO LEITEIRA

Lucas Rover
Universidade Tecnológica Federal do Paraná (UTFPR)
lucasrover@alunos.utfpr.edu.br
Gabriela Giusti
Universidade Federal de São Carlos (UFSCar)
gabriela.giusti@hotmail.com.br
Daiane Vitória da Silva
Universidade Federal de São Carlos (UFSCar)
Diogo Aparecido Lopes Silva
Universidade Federal de São Carlos (UFSCar)
diogo.apls@ufscar.br
Yara de Souza Tadano
Universidade Tecnológica Federal do Paraná (UTFPR)
yaratadano@utfpr.edu.br

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já os usam para estimar fatores, revisar inventários e gerar análises, sem protocolo ou quantificação do erro.

Não se encontraram estudos que testem sistematicamente estimativas de LLMs contra ACVs auditadas, regionalizadas e com controle de contaminação. Saídas de LLMs são fluentes mesmo quando incorretas (JI *et al.*, 2023), e reproduzem na inferência dados vistos no treinamento (CARLINI *et al.*, 2023; SAINZ *et al.*, 2023). Categorias sensíveis a condições locais, como a formação de material particulado (MP) (GIUSTI *et al.*, 2023), ainda são avaliadas com fatores de caracterização (FCs) globais, dado que as abordagens regionalizadas para o Brasil são recentes, como o modelo de Oberschelp *et al.* (2020), recomendado para o Brasil por Giusti *et al.* (2022) e consistente com o arcabouço do *Global Guidance for LCIA Indicators and Methods* (GLAM) (LIFE CYCLE INITIATIVE, 2024).

Pergunta-se: em que ponto da escala de enriquecimento de prompt o LLM passa a produzir uma estimativa confiável para a formação de material particulado?

2 METODOLOGIA

2.1 ARTIGO-REFERÊNCIA E *GROUND TRUTH*

Recortaram-se dois estudos de caso de Giusti *et al.* (2023), de perfis extremos: um sistema confinado em São Paulo (S1) e um semi-intensivo, de base pastoril, no Paraná (S2), na perspectiva *cradle-to-farm gate* (ABNT NBR ISO 14040/14044, 2009), com unidade funcional de 1 kg FPCM (*fat-and-protein corrected milk*). Adotou-se o modelo de Oberschelp *et al.* (2020) com efeito *Average* no nível do solo, nos três níveis de regionalização

(global, nacional e estadual), e alocação econômica. A reconciliação partiu do material suplementar de Oberschelp e da planilha pública de Giusti (discrepância $< 0{,}1\%$), resultando em seis células de *ground truth* em DALY/kg FPCM (*Disability-Adjusted Life Years*; Tabela 1).

Tabela 1 – *Ground truth* — Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	Sistema 1 (SP)	Sistema 2 (PR)
Global	$2{,}830 \times 10^{-8}$	$1{,}281 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$	$1{,}096 \times 10^{-7}$
Estado-alvo	$6{,}373 \times 10^{-7}$	$1{,}554 \times 10^{-7}$
Razão Estado/Global	$22{,}5\times$	$12{,}1\times$

Nota: as razões diferem por perfil de emissão e estado-alvo. Fonte: elaborada pelos autores a partir de Giusti *et al.* (2023) e Oberschelp *et al.* (2020).

2.2 VARIÁVEL INDEPENDENTE: NÍVEIS DE ENRIQUECIMENTO DE PROMPT

Cinco níveis (L0–L4) acrescentam, cada um, uma dimensão de informação: L0 (apenas a pergunta); L1 (escopo ISO 14040/14044); L2 (inventário dos 28 fluxos elementares relevantes à formação de MP no Sistema 1); L3 (FCs de Oberschelp *et al.* (2020) nos três níveis de regionalização); L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, em que m_i é a massa do fluxo i e $CF_{i,g}$ o fator de caracterização no escopo g). O inventário do ciclo de vida (ICV) e a planilha de FCs foram entregues em versão trabalhada, apenas com as variáveis necessárias ao cálculo. A formulação de L4 segue a lógica de *chain-of-thought prompting* (WEI *et al.*, 2022).

2.3 MODELOS LLM E DESENHO EXPERIMENTAL

Foram avaliados três LLMs: GPT-4.1 (OpenAI, `gpt-4.1-2025-04-14`; ACHIAM *et al.*, 2023), Gemini 2.5 Pro (Google; GEMINI TEAM, 2025) e DeepSeek V3 (DEEPSEEK-AI, 2024). Cada combinação sistema $\times$ LLM $\times$ nível (L0–L4) $\times$ idioma (PT-BR; EN) foi replicada $n = 5$ vezes sob temperatura nula ($T = 0$) e *seed* 42. APIs proprietárias podem ter não-determinismo residual mesmo sob $T = 0$ (ROVER *et al.*, 2026); o Gemini não expõe *seed*. *System prompt* e esquema JSON estão no Material Complementar[1]. O experimento principal reúne 300 chamadas e o teste de contaminação, 180.

2.4 MÉTRICAS E ANÁLISE

Calcularam-se o erro relativo absoluto e o MAPE (*Mean Absolute Percentage Error*), a aderência metodológica (modelo de FC e alocação declarados) e a sensibilidade regional; a estabilidade foi medida por taxa de não-resposta, conformidade ao esquema JSON e coeficiente de variação (CV) intra-célula. Dois limiares foram fixados *a priori*. O de 30%, critério operacional de concordância, corresponde à ordem de grandeza da divergência entre os modelos de caracterização recomendados para o Brasil (GIUSTI *et al.*, 2022; HEIJUNGS; DEKKER, 2022); abaixo dele, a estimativa não altera a conclusão comparativa. O de 10% separa cálculo de reprodução (seção 2.5) e supera em mais de duas ordens de grandeza o CV intra-célula do Gemini em L3/L4 ($\leq 0{,}0003$), modelo cujo sinal de memorização domina a classificação, de modo que a classe não é artefato do ruído.

[1] Material Complementar e *scripts*: `https://github.com/Roverlucas/ia-acv-gcv2026`.

2.5 CONTROLE DE CONTAMINAÇÃO POR TREINAMENTO

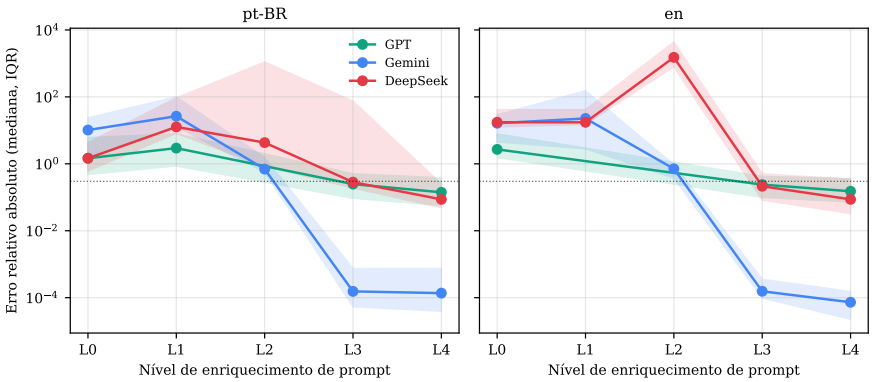
Publicado em 2023, o artigo-referência antecede o *cutoff* dos LLMs avaliados, o que abre a hipótese de memorização (CARLINI *et al.*, 2023). Para discriminar memorização de cálculo, replicaram-se L3 e L4 em PT-BR ($n = 5$) com três esquemas de inventário perturbado por sistema (massas $\times$ 2; amônia $\times$ 0,1; substâncias $\times$ U[0,5; 2,0], *seed* fixa). O prompt informa explicitamente que o inventário é hipotético. Cada chamada produz dois erros: Δ_{novo} contra o *ground truth* recalculado e Δ_{orig} contra o valor publicado. As perturbações afastam o *ground truth* recalculado do publicado, tornando as classes disjuntas (nenhuma das 180 chamadas satisfez ambos). Classifica-se como *cálculo* se $|\Delta_{\text{novo}}| < 10\%$ e como *memorização* se $|\Delta_{\text{orig}}| < 10\%$; *misto* quando nenhum critério é satisfeito e *null* quando há recusa numérica. Memorização é usada em sentido operacional, reproduzir o valor publicado apesar de dados alterados, não como extração *verbatim* de treino, cuja verificação exigiria acesso aos corpora.

3 RESULTADOS

3.1 CURVA DE SATURAÇÃO MAPE $\times$ NÍVEL

Das 300 chamadas, 295 retornaram JSON estritamente conforme; as cinco exceções foram todas do DeepSeek (quatro em inglês, uma em PT-BR): duas respostas vazias, duas falhas de *parsing* em L3/L4 EN, uma recuperada por leitura tolerante. Na Figura 1, o salto principal de acurácia ocorre entre L2 e L3, e o erro cai a valores próximos de zero em L3 e L4. A seção 3.4 mostra que essa convergência é produto de memorização, não de cálculo.

Figura 1 – Erro relativo absoluto (mediana, IQR) por nível, LLM e idioma (PT-BR; EN). Eixo *y* logarítmico; linha tracejada: limiar de 30%.



Fonte: autores.

3.2 COMPORTAMENTO METODOLÓGICO (MODELO DECLARADO)

Em L0–L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), recomendado para o Brasil por Giusti *et al.* (2022). GPT e Gemini citaram ReCiPe 2016 (HUIJBREGTS *et al.*, 2017; base em Van Zelm *et al.*, 2016) e DeepSeek citou IMPACT World+ (BULLE *et al.*, 2019), regionalizado para a América Latina mas sem o detalhamento estadual de Oberschelp nem a base de *effect factors* de Fantke *et al.* (2019). Os LLMs recorrem a FCs consolidados em *softwares* de avaliação de impacto do ciclo de vida (AICV), não a modelos publicados ainda não integrados a ferramentas.

3.3 CONCORDÂNCIA OPERACIONAL

A fração de estimativas dentro do critério de 30% é nula ou marginal em L0–L2. No Sistema 1, em L3, GPT e Gemini atingem 100% nos dois idiomas e DeepSeek, 47% (PT-BR) e 67% (EN); em L4, os três atingem 100%.

3.4 ACHADO CENTRAL: MEMORIZAÇÃO VS. CÁLCULO

Em L0–L2, os três LLMs reportam razões Estado/Global medianas entre 0,5× e 3,0×, ante as 22,5× e 12,1× publicadas (Tabela 1). Em L3–L4, o Gemini reproduz a razão exata (22,52× e 12,13×) e GPT e DeepSeek aproximam-se (±10–60%). O GPT retornou `null` em 100% das chamadas de L2 e em L1 EN (mas respondeu em L1 PT-BR), alegando ausência de FCs suficientes. Essa recusa não é falha: enquanto Gemini e DeepSeek estimaram em L0–L2 com erros de até duas ordens de grandeza, o GPT sinalizou o limite da própria informação. Em ACV, onde um número errado alimenta declarações ambientais indevidas, abster-se é preferível a responder com fluência infundada.

O teste de contaminação (Tabela 2) mostra o Gemini reproduzindo o *ground truth* com erro $< 0{,}5\%$ e CV nulo em L3/L4 e, sob inventário perturbado, classificando-se como memorização em 29 de 30 chamadas por sistema. O GPT memoriza S1 (27/30) e quase nunca S2 (3/30), e o DeepSeek memoriza menos (13/30 em S1; 0/30 em S2). O aviso de que o inventário era hipotético não alterou o resultado.

A assimetria pode decorrer da densidade desigual dos casos nos corpora: o sistema confinado paulista seria mais recorrente na literatura de ACV leiteira brasileira que os pastoris sulistas. O viés geográfico da produção científica seria herdado pelas ferramentas que a medeiam, deixando regiões menos estudadas com estimativas menos ancoradas onde a regionalização mais importa.

O L4 entrega o procedimento de cálculo de forma explícita, sob a lógica de *chain-of-thought prompting* (WEI *et al.*, 2022), e ainda assim o modelo ignora os números do prompt para devolver o resultado armazenado no pré-treinamento. A contaminação anula a cadeia de raciocínio em vez de ser corrigida por ela: engenharia de prompt não garante confiabilidade quando o caso já está no corpus.

Tabela 2 – Teste de contaminação: classificação das chamadas L3+L4 PT-BR ($n = 30$ por LLM por sistema)

	Sistema 1 (SP)				Sistema 2 (PR)			
LLM	Calc.	Mem.	Misto	Null	Calc.	Mem.	Misto	Null
GPT	0	27	3	0	0	3	27	0
Gemini	1	29	0	0	1	29	0	0
DeepSeek	1	13	15	1	4	0	21	5

Critérios na seção 2.5. IC_{95} (Clopper–Pearson) da memorização — S1: GPT [0,73; 0,98], Gemini [0,83; 1,00], DeepSeek [0,25; 0,63]; S2: GPT [0,02; 0,27], Gemini [0,83; 1,00], DeepSeek [0,00; 0,12]. Fonte: autores.

A diferença Gemini–DeepSeek é consistente nos dois sistemas, com IC 95% (Clopper–Pearson, $n = 30$) não-sobrepostos (Tabela 2); como sob $T = 0$ as réplicas de um mesmo esquema são quase-determinísticas, a unidade independente é o agrupamento esquema×nível ($n = 6$): a separação persiste no Sistema 2 (Fisher exato $p = 0{,}002$), não no Sistema 1 ($p = 0{,}18$). A classificação é robusta ao limiar: entre ±5% e ±15% o Gemini mantém 29/30 e o DeepSeek-S2, 0/30. Em L0–L2 o CV do Gemini chegou a 1,9, com estimativas diferindo em uma ordem de grandeza sob $T = 0$.

3.5 LIMITAÇÕES

O desenho cobre dois sistemas, um modelo de caracterização e três LLMs, o que limita a generalização. Com $n = 5$ por célula, as comparações de erro contínuo (MAPE, razões) são descritivas; os intervalos de confiança das proporções de memorização descrevem a incerteza amostral e não substituem um teste de hipótese sobre médias. A memorização é inferida do comportamento, não verificada na fonte: sem acesso aos corpora, não se descarta ancoragem em valores plausíveis, embora a reprodução do valor exato com CV nulo a torne improvável. APIs proprietárias são atualizadas e depreciadas sem aviso, e a réplica exata do teste depende da permanência das versões avaliadas (ROVER *et al.*, 2026).

4 CONCLUSÕES

A acurácia aparente em L3 e L4 é reprodução do artigo-referência, não cálculo, e o gradiente entre modelos e a assimetria entre sistemas sugerem que o artigo chegou aos corpora em doses distintas. No uso informal típico (L0–L1), o erro vai de cerca de 2 a 900 vezes o valor publicado, com subestimação da diferenciação regional em uma a duas ordens de grandeza.

Nenhum comportamento observado satisfaz os requisitos de uma ACV regionalizada como a de Giusti *et al.* (2023). Recomenda-se que LLMs não sejam empregados como motores de cálculo de impacto (AICV): quando acertam, o acerto some assim que o caso sai do que foi memorizado, situação de qualquer estudo novo. O uso seguro está no processamento de linguagem natural, como converter inventários textuais não estruturados em formato legível por máquina, delegando a caracterização regional e o cálculo a sistemas determinísticos.

Conflito de interesse. Gabriela Giusti e Yara de Souza Tadano são autoras do artigo-referência; a comparação usou apenas números publicados, sem reanálise do dado bruto.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.
ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental — avaliação do ciclo de vida — princípios e estrutura. Rio de Janeiro: ABNT, 2009.
ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental — avaliação do ciclo de vida — requisitos e orientações. Rio de Janeiro: ABNT, 2009.
BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.
BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.
CARLINI, N. *et al.* Quantifying memorization across neural language models. In: **International Conference on Learning Representations** (ICLR), 2023.
DEEPSEEK-AI. DeepSeek-V3 Technical Report. **arXiv preprint**, arXiv:2412.19437, 2024.
FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.
GEMINI TEAM. Gemini 2.5: pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. **Google DeepMind Technical Report**, 2025.
GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.
GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.
HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.
HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.
JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.
LIFE CYCLE INITIATIVE. **GLAM — Global Guidance for LCIA Indicators and Methods**. UNEP Life Cycle Initiative, 2024. Disponível em: `https://www.lifecycleinitiative.org/activities/`. Acesso em: 21 out. 2024.
OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.
ROVER, L. *et al.* Same prompt, different answer: hidden non-determinism in LLM APIs undermines scientific reproducibility. **Nature Communications** (em revisão), 2026. DOI: 10.6084/m9.figshare.31653373.
SAINZ, O. *et al.* NLP evaluation in trouble: on the need to measure LLM data contamination for each benchmark. In: **Findings of EMNLP**, 2023.
VAN ZELM, R. *et al.* Regionalized human health characterization factors for particulate matter exposure for use in life cycle assessment. **Atmospheric Environment**, v. 134, p. 213–220, 2016.
WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.