TESTE DE CONTAMINAÇÃO EM LLMS APLICADOS À ACV REGIONALIZADA DO MATERIAL PARTICULADO EM PRODUÇÃO LEITEIRA

Lucas Rover
Universidade Tecnológica Federal do Paraná (UTFPR)
lucasrover@alunos.utfpr.edu.br
Yara de Souza Tadano
Universidade Tecnológica Federal do Paraná (UTFPR)
yaratadano@utfpr.edu.br

Declaração de conflito de interesse. A coautora Yara de Souza Tadano é coautora do paper-referência (Giusti *et al.*, 2023). Toda comparação foi feita contra os números publicados, sem reanálise privilegiada do dado bruto. Repositório público com 480 chamadas, prompts e scripts: `https://github.com/Roverlucas/ia-acv-gcv2026`.

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já usam essas ferramentas para estimar fatores, revisar inventários e gerar análises a partir de descrições em linguagem natural sem protocolo, sem auditoria e sem medida de erro.

Três lacunas convergentes motivam este trabalho. Primeiro, até onde alcançamos, nenhum estudo testa sistematicamente estimativas de LLMs contra ACVs auditadas, regionalizadas e com controle de contaminação. Segundo, saídas de LLMs são fluentes mesmo quando incorretas (JI *et al.*, 2023); modelos também memorizam dados de treinamento e os reproduzem na inferência (CARLINI *et al.*, 2023; SAINZ *et al.*, 2023). Terceiro, a regionalização de impactos para material particulado (MP) em saúde humana no Brasil (GIUSTI *et al.*, 2022, 2023) costuma ser substituída por fatores globais quando o modelo é consultado sem dados específicos. A pergunta é: **em que ponto da escala de enriquecimento de prompt o LLM passa a produzir uma estimativa de ACV utilizável?**

Resultado central. A acurácia aparente em níveis enriquecidos não vem de cálculo, mas de **memorização do paper-referência**. Sob inventário perturbado, 97% das chamadas do Gemini (em dois sistemas), 90% do GPT no Sistema 1 e 43% do DeepSeek no Sistema 1 continuam reportando o valor publicado, ignorando os dados. O efeito varia entre LLMs e sistemas: o modelo recupera com mais facilidade casos muito citados no corpus.

2 METODOLOGIA

2.1 PAPER-REFERÊNCIA E *GROUND TRUTH*

O estudo de Giusti *et al.* (2023) analisa quatro sistemas de produção leiteira brasileiros (*cradle-to-farm gate*; ABNT NBR ISO 14040, 2009; ABNT NBR ISO 14044, 2009), com dade funcional de 1 kg FPCM (*fat-and-protein corrected milk*), e aplica cinco modelos

de caracterização com três níveis de regionalização. Fixamos dois sistemas (S1 confinado típico, SP; S2 semi-intensivo, PR), o modelo de OBERSCHELP *et al.* (2020) com efeito *Average* a nível do solo, e alocação econômica. Resulta um *ground truth* de seis células em DALY/kg FPCM (Tabela 1). Os fatores nativos foram extraídos do material suplementar de Oberschelp e reconciliados com a planilha de Giusti (discrepância $< 0{,}1\%$).

Tabela 1 – Ground truth Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	**Sistema 1 (SP)**	**Sistema 2 (PR)**
Global	$2{,}830 \times 10^{-8}$	$1{,}281 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$	$1{,}096 \times 10^{-7}$
Estado-alvo	$6{,}373 \times 10^{-7}$	$1{,}554 \times 10^{-7}$
Razão Estado/Global	$22{,}5\times$	$12{,}1\times$

Razões diferentes refletem distintos perfis de emissão por sistema e estados-alvo distintos.

2.2 VARIÁVEL INDEPENDENTE NÍVEIS DE ENRIQUECIMENTO DE PROMPT

Cinco níveis ordenados foram desenhados, cada um adicionando uma dimensão de informação ao anterior: L0 (apenas a pergunta), L1 (escopo ISO 14040/14044), L2 (inventário agregado de 28 fluxos PM-relevantes do Sistema 1, selecionados conforme o subconjunto de poluentes do modelo Oberschelp), L3 (tabela de fatores de caracterização Oberschelp para os três escopos) e L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, no espírito de *chain-of-thought prompting*, WEI *et al.*, 2022).

2.3 MODELOS LLM E DESENHO EXPERIMENTAL

Foram avaliados três LLMs de fronteira: GPT-4.1 (OpenAI, `gpt-4.1-2025-04-14`), Gemini 2.5 Pro (Google) e DeepSeek V3. Para cada sistema, cada combinação *LLM* $\times$ *nível* $\times$ *idioma (PT-BR, EN)* foi replicada $n = 5$ vezes, temperatura zero e *seed* 42 nas APIs que expõem o parâmetro (Gemini não o expõe; sua estabilidade foi verificada *a posteriori* por CV intra-célula em L3/L4, próximo de zero). O *system prompt*, a nota experimental do teste de contaminação e o esquema JSON de resposta são reproduzidos no Material Complementar e versionados no repositório público (URL na primeira página). Total: 300 chamadas (US$ 3,42, 108 min de *wall-clock* agregado). Somadas às 180 do teste de contaminação (ğ2.5), o estudo perfaz **480 chamadas registradas**. Três falhas de *parsing* (DeepSeek L4 EN) foram recuperadas por avaliação aritmética das expressões fornecidas no campo `value`; nenhuma exigiu reexecução.

2.4 MÉTRICAS E ANÁLISE

Foram computadas: erro relativo absoluto e MAPE; aderência metodológica (modelo e alocação declarados); sensibilidade regional; e estabilidade (não-resposta, conformidade JSON, CV intra-célula). Critério operacional: erro $< 30\%$. Como limitação, $n = 5$ é suficiente para LLMs determinísticos sob $T = 0$ mas não permite testes inferenciais; comparações usam estatística descritiva.

2.5 CONTROLE DE CONTAMINAÇÃO POR TREINAMENTO

O paper-referência foi publicado em 2023, anterior ao *cutoff* de treinamento dos LLMs, o que abre a hipótese de memorização (CARLINI *et al.*, 2023). Para discriminar memorização de cálculo, replicamos L3 e L4 em PT-BR ($n = 5$) com três esquemas de inventário perturbado, em cada sistema: P1 (massas $\times$ 2); P2 (amônia $\times$ 0,1); P3 (cada substância $\times$ U[0,5; 2,0], seed fixa). O prompt traz nota experimental explícita informando que o inventário é hipotético. Cada chamada produz dois erros simultâneos: Δ_{novo} contra o novo *ground truth* calculado e Δ_{orig} contra o valor publicado. Classifica-se como *cálculo* quando $|\Delta_{\text{novo}}| < 10\%$, *memorização* quando $|\Delta_{\text{orig}}| < 10\%$, *misto* quando nenhum dos dois critérios é satisfeito e *null* quando o LLM recusa numericamente. Total: 180 chamadas adicionais (90 por sistema). Conflito de interesse: a versão final declarará vínculo entre autoria e paper-referência.

3 RESULTADOS

Das 300 chamadas do experimento principal, 297 retornaram JSON conforme o esquema (3 falhas de parsing em DeepSeek L4 EN). A taxa de resposta numérica não-`null` variou por nível e por LLM, com o GPT apresentando recusa sistemática em níveis com informação insuficiente.

3.1 CURVA DE SATURAÇÃO MAPE $\times$ NÍVEL

A Figura 1 apresenta a mediana e o intervalo interquartil do erro relativo absoluto por nível, LLM e idioma. À primeira vista, o salto principal de acurácia ocorre entre L2 e L3 e o erro cai a valores próximos de zero em L3 e L4. Essa aparente convergência é, no entanto, o sintoma central deste trabalho: como mostraremos em ğ3.4, ela é produto de memorização do paper-referência, não de cálculo.

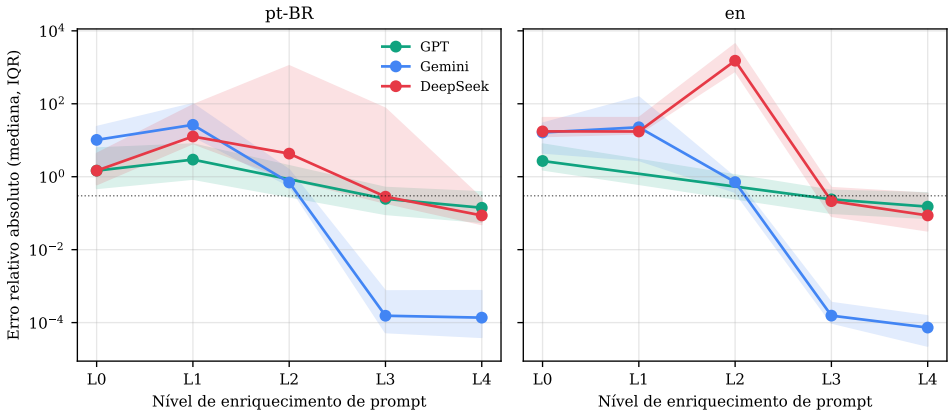


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) por nível de enriquecimento de prompt, LLM e idioma. Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%.

3.2 COMPORTAMENTO METODOLÓGICO (MODELO DECLARADO)

Em L0L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), apesar de ser o modelo regionalizado para o Brasil. GPT e Gemini citaram ReCiPe 2016 (HUIJBREGTS *et al.*, 2017); DeepSeek citou IMPACT World+ (BULLE *et al.*, 2019). A partir de L3, todos seguiram a instrução, confirmando a recomendação de HEI-

JUNGS & DEKKER (2022) de explicitar o modelo e o limite prático de fatores globais (FANTKE *et al.*, 2019) em escala regional.

3.3 CONCORDÂNCIA OPERACIONAL

A fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto é nula ou marginal em L0L2 em quase todas as células. Em L3, GPT e Gemini atingem 100% em ambos os idiomas; DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4 todos os três LLMs atingem 100%.

3.4 ACHADO CENTRAL: MEMORIZAÇÃO VS. CÁLCULO

Diferenciação regional. A razão Estado/Global publicada é 22,5× (S1) e 12,1× (S2). Em L0–L2, os três LLMs reportam razões entre 1,0× e 3,0×, subestimando a diferenciação em uma a duas ordens de magnitude. Em L3–L4, Gemini reproduz a razão exata em ambos os sistemas (22,52× e 12,13×); GPT e DeepSeek aproximam-se (±10–60%). DeepSeek em L2 não diferencia regiões em 100% das chamadas.

Recusa do GPT. Retornou `null` em 100% das chamadas de L2 (ambos os sistemas) e em L1 EN, justificando ausência de fatores (ACHIAM *et al.*, 2023).

Resultado do teste de contaminação (Tabela 2). O Gemini reproduziu o *ground truth* com erro $< 0{,}5\%$ e CV nulo em L3/L4. Sob inventário perturbado, classifica-se como *memorização* em 29 de 30 chamadas em cada sistema. GPT memoriza S1 (27/30) e quase nunca S2 (3/30, com 27 *mistas*). DeepSeek tem o menor padrão (13/30 S1; 0/30 S2). A nota experimental no prompt não alterou o resultado.

Tabela 2 – Teste de contaminação: classificação das chamadas L3+L4 PT-BR ($n = 30$ por LLM por sistema) com intervalo de confiança 95% (Clopper–Pearson) da taxa de memorização.

	Sistema 1 (SP)					Sistema 2 (PR)				
LLM	Calc.	Mem.	Misto	Null	IC_{95}(Mem.)	Calc.	Mem.	Misto	Null	IC_{95}(Mem.)
GPT	0	27	3	0	[0,73; 0,98]	0	3	27	0	[0,02; 0,27]
Gemini	1	29	0	0	[0,83; 1,00]	1	29	0	0	[0,83; 1,00]
DeepSeek	1	13	15	1	[0,25; 0,63]	4	0	21	5	[0,00; 0,12]

A análise de sensibilidade ao limiar de classificação (±5% vs. ±15%, ver Material Complementar) preserva o ordenamento das taxas e o caráter robusto da diferença Gemini–DeepSeek.

Variância em L0L2. CV intra-célula chegou a 1,2 no Gemini; estimativas diferindo em até uma ordem de grandeza entre repetições mesmo sob $T = 0$.

4 CONCLUSÕES

Para os dois sistemas testados, a acurácia aparente dos LLMs em L3 e L4 vem da memorização do paper-referência, não de cálculo. O gradiente Gemini → GPT → DeepSeek e a diferença GPT entre Sistema 1 e Sistema 2 sugerem que o paper-alvo chegou aos corpora de treinamento em doses distintas e que o modelo recupera com mais facilidade casos muito citados.

No uso informal típico (L0 e L1, sem dados), os erros variam de uma faixa de 2 a 273 vezes o valor publicado; nenhum LLM seleciona o modelo regionalizado, convergindo para ReCiPe 2016 (GPT, Gemini) ou IMPACT World+ (DeepSeek). A magnitude da diferenciação regional é subestimada em uma a duas ordens de grandeza.

A matriz completa (4 sistemas × 5 modelos × 3 escopos) será apresentada em trabalho subsequente, incluindo triangulação contra modelos de caracterização alternativos. **O ponto operacional, contudo, já se sustenta para os casos testados: se o caso está documentado na literatura, o LLM tende a devolver o número publicado e ignorar o inventário fornecido; quando não está, devolve um fator global genérico (ReCiPe 2016 ou IMPACT World+).** Nenhum dos dois comportamentos satisfaz os requisitos de uma ACV regionalizada nos termos da ISO 14044. A recomendação prática derivada é restringir o uso atual de LLMs em ACV a tarefas auxiliares (rascunho de Goal & Scope, revisão linguística) e considerar arquiteturas de *retrieval-augmented generation* ancoradas em tabelas verificadas de fatores como caminho para mitigação.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.

CARLINI, N. *et al.* Quantifying memorization across neural language models. In: **International Conference on Learning Representations** (ICLR), 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental avaliação do ciclo de vida princípios e estrutura. Rio de Janeiro: ABNT, 2009.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental avaliação do ciclo de vida requisitos e orientações. Rio de Janeiro: ABNT, 2009.

BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.

BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.

FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.

GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.

GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.

HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.

HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.

JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.

OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.

SAINZ, O. *et al.* NLP evaluation in trouble: on the need to measure LLM data contamination for each benchmark. In: **Findings of EMNLP**, 2023.

WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.