ACURÁCIA DE LLMS EM ESTUDOS DE ACV REGIONALIZADA: EFEITO DO ENRIQUECIMENTO CONTEXTUAL DO PROMPT EM ESTIMATIVAS DO IMPACTO DO MATERIAL PARTICULADO

[Identificação dos autores omitida para revisão por pares]

1 INTRODUÇÃO

A evolução na coleta e no processamento de dados em Avaliação do Ciclo de Vida (ACV) tem culminado no uso crescente de ferramentas digitais, como modelos de linguagem de grande porte (LLMs), na aplicação da metodologia. Praticantes pesquisadores, consultores e alunos já recorrem a LLMs informalmente para estimar fatores ausentes, revisar inventários e, em alguns casos, gerar resultados completos a partir de prompts em linguagem natural (BROWN *et al.*, 2020). Esse uso ocorre, em geral, sem protocolo, sem auditoria e sem evidência quantitativa de acurácia.

A literatura apresenta três lacunas convergentes: (i) ausência de validação empírica que quantifique o erro de LLMs frente a ACVs publicadas com metodologia rastreável; (ii) confusão entre acurácia e plausibilidade, dado que saídas de LLMs são fluentes mesmo quando incorretas; e (iii) regionalização tipicamente ignorada, com LLMs respondendo com fatores genéricos globais e omitindo especificidades regionais empiricamente relevantes para impactos de material particulado (MP) em saúde humana no Brasil (GIUSTI *et al.*, 2022, 2023). A pergunta operacional decorrente é: **em que ponto da escala de enriquecimento contextual do prompt a IA passa a produzir um resultado de ACV utilizável?** Este resumo expandido apresenta um desenho experimental controlado que testa essa hipótese tomando como benchmark a ACV regionalizada de Giusti *et al.* (2023) para sistemas de produção leiteira brasileiros.

2 METODOLOGIA

2.1 Paper-benchmark e *ground truth*

O estudo de Giusti *et al.* (2023) analisa quatro sistemas de produção leiteira brasileiros (*cradle-to-farm gate*, unidade funcional de 1 kg FPCM *fat-and-protein corrected milk*) e aplica cinco modelos de caracterização com três níveis de regionalização. Para este resumo expandido, restringimos a análise ao Sistema 1 (sistema confinado típico), modelo de caracterização Oberschelp *et al.* (2020) com modelo de efeito *Average* a nível do solo, e alocação econômica, produzindo um *ground truth* de três células de impacto em DALY/kg FPCM (Tabela 1). Os fatores de caracterização nativos foram extraídos do material suplementar de Oberschelp *et al.* (2020) e cross-validados contra a planilha de cálculo de Giusti *et al.* (2023), com concordância $< 0{,}1\%$.

2.2 Variável independente níveis de enriquecimento de prompt

Cinco níveis ordenados foram desenhados, cada um adicionando uma única dimensão de informação ao anterior: L0 (apenas pergunta), L1 (+ escopo ISO 14040/14044), L2 (+ inventário agregado de 28 fluxos PM-relevantes), L3 (+ tabela de fatores de caracterização Oberschelp para os 3 escopos) e L4 (+ procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$).

Tabela 1 – Ground truth Sistema 1, Oberschelp (2020) *Average*, alocação econômica

Escopo geográfico	Impacto (DALY/kg FPCM)
Global	$2{,}830 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$
Estado de São Paulo	$6{,}373 \times 10^{-7}$

Razão SP/Global $\approx 22{,}5\times$.

2.3 Modelos LLM e desenho

Foram avaliados três modelos LLM de fronteira: GPT (OpenAI), Gemini 2.5 Pro (Google) e DeepSeek V3 (open-source). Cada combinação *LLM* $\times$ *nível* $\times$ *idioma (PT-BR, EN)* foi replicada $n = 5$ vezes com temperatura fixa em 0 e *seed* controlado quando suportado. Resposta exigida em formato JSON estrito (esquema canônico). Total: **150 chamadas**, custo total US$ 1,71, tempo de execução 54 minutos.

2.4 Métricas

Foram computadas quatro famílias: **(A)** acurácia numérica (erro relativo absoluto, MAPE, log-razão $\log_{10}(\hat{I}/I_{GT})$); **(B)** corretude metodológica (modelo de caracterização declarado, alocação declarada); **(C)** fidelidade regional (a estimativa diferencia regiões? coincide em direção com GT?); e **(D)** confiabilidade (taxa de não-resposta, conformidade ao esquema JSON, coeficiente de variação intra-modelo). O critério operacional de concordância adota erro relativo absoluto $< 30\%$.

3 RESULTADOS

Todas as 150 chamadas retornaram JSON estritamente conforme o esquema (zero falhas de parsing). A taxa de resposta numérica (não-`null`) variou por nível e LLM, com GPT apresentando comportamento defensivo distinto.

3.1 Curva de saturação MAPE $\times$ nível

A Figura 1 apresenta a curva de saturação do erro relativo absoluto. O salto principal ocorre entre L2 e L3 (i.e., ao fornecer os fatores de caracterização), com convergência em L3/L4 para erros próximos a zero. A Tabela 2 resume os MAPE por LLM, nível e idioma.

Tabela 2 – MAPE por LLM $\times$ idioma $\times$ nível (média sobre 3 escopos $\times$ 5 reps).

LLM	Idioma	L0	L1	L2	L3	L4
GPT	PT-BR	$+2.5\times$	$+3.9\times$	—	+20%	+11%
GPT	EN	$+2.5\times$	—	—	+17%	+7%
Gemini	PT-BR	$+5.8\times$	$+273.2\times$	$+2.6\times$	+0%	+0%
Gemini	EN	$+16.9\times$	$+110.0\times$	+65%	+0%	+0%
DeepSeek	PT-BR	$+2.1\times$	$+89.4\times$	$+2.2\times$	+32%	+5%
DeepSeek	EN	$+20.2\times$	$+20.2\times$	$+2017.9\times$	+15%	+5%

Erro relativo absoluto médio (MAPE). Valores apresentados em % até 100%; acima disso, em múltiplos do GT ($\times$).

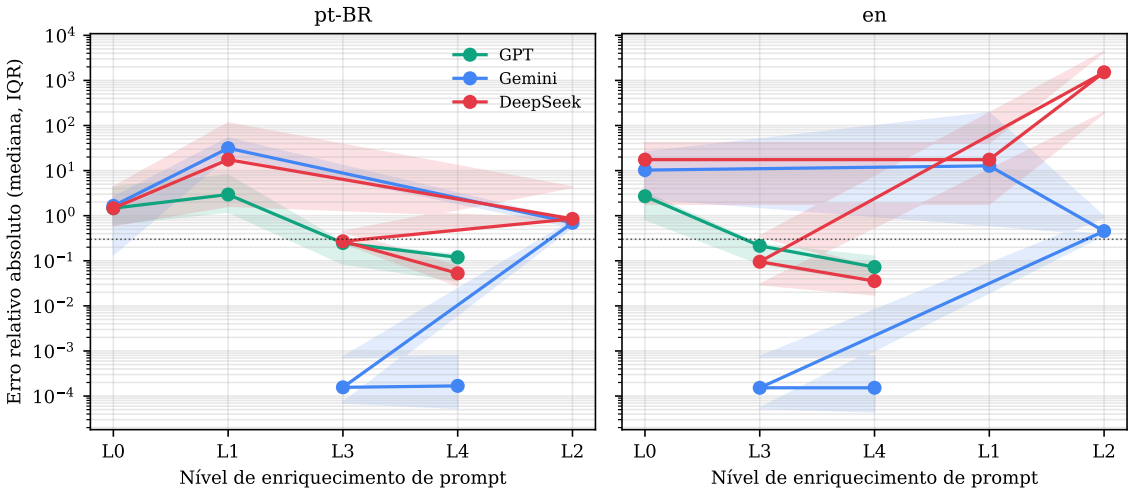


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) vs. nível de enriquecimento de prompt, por LLM e idioma. Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%.

3.2 Comportamento metodológico (modelo declarado)

Em L0–L2, nenhum dos LLMs selecionou espontaneamente o modelo Oberschelp *et al.* (2020), mesmo este sendo o modelo nativamente regionalizado para o Brasil. As escolhas foram divididas entre ReCiPe 2016 (GPT, Gemini, predominantemente) e IMPACT World+ (DeepSeek, predominantemente), conforme Tabela 3. A partir de L3, quando o modelo é explicitamente indicado, todos seguiram a instrução (29/30 em L3+L4 em PT-BR).

Tabela 3 – Modelo de caracterização declarado pelas LLMs por nível (PT-BR, contagem agregada).

Nível	Oberschelp	Recipe	Impact World	Other	Unspecified
L0	0	9	6	0	0
L1	0	10	5	0	0
L2	0	5	5	5	0
L3	14	0	0	0	1
L4	15	0	0	0	0

3.3 Concordância operacional

A Figura 2 e a Tabela 4 mostram a fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto. Em L0–L2 essa fração é praticamente nula em todos os LLMs (0% na vasta maioria das células). Em L3, GPT e Gemini atingem 100% em ambos os idiomas; DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4 todos os três LLMs atingem 100%.

3.4 Achados específicos

Não-resposta defensiva (GPT). GPT retornou `null` em 100% das 10 chamadas de L2 (PT-BR e EN) e em 100% das 5 chamadas de L1 EN, justificando explicitamente a ausência de fatores de caracterização como impeditivo do cálculo. Esse comportamento é replicável e indica adesão à regra de honestidade epistêmica do *system prompt*.

Reprodutibilidade do Gemini em L3/L4. Em 60 chamadas (5 reps $\times$ 3 escopos $\times$ 2 idiomas $\times$ 2 níveis), Gemini reproduziu o GT com erro relativo $< 0{,}5\%$ e coeficiente de variação intra-célula de zero. GPT (CV $\sim$0,08–0,10) e DeepSeek (CV $\sim$0,02) também se aproximaram

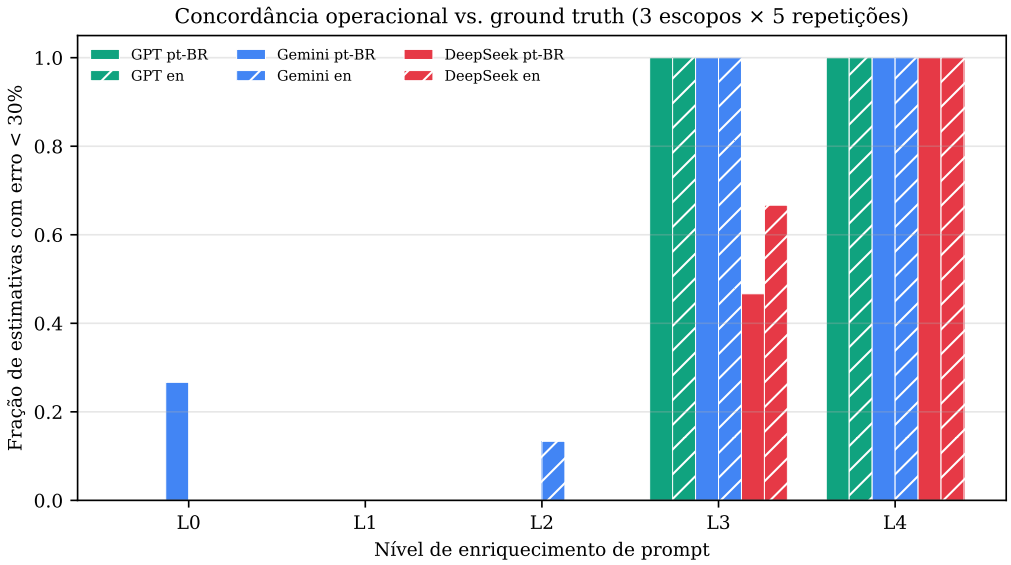


Figura 2 – Fração de estimativas com erro relativo absoluto $< 30\%$ (critério operacional de concordância).

Tabela 4 – Fração de estimativas com erro relativo absoluto $< 30\%$ (critério operacional de concordância).

LLM	Idioma	L0	L1	L2	L3	L4
GPT	PT-BR	0%	0%	0%	100%	100%
GPT	EN	0%	0%	0%	100%	100%
Gemini	PT-BR	27%	0%	0%	100%	100%
Gemini	EN	0%	0%	13%	100%	100%
DeepSeek	PT-BR	0%	0%	0%	47%	100%
DeepSeek	EN	0%	0%	0%	67%	100%

do GT em L4, mas com maior variância e desvio.

Variância em L0–L2. O coeficiente de variação intra-célula em L0–L2 chegou a 1,2 para Gemini, indicando estimativas drasticamente diferentes entre repetições mesmo com temperatura nula — contrastando com a reprodutibilidade perfeita em L3/L4 do mesmo modelo.

4 CONCLUSÕES

O experimento responde diretamente à pergunta de pesquisa. **(i)** A assertividade da IA em estudos de ACV depende drasticamente do nível de informação contextual fornecida no prompt: em L0–L1, os erros típicos são de 2–273 vezes o ground truth, contradizendo o uso informal observado de LLMs como "oráculo" de estimativas de impacto. **(ii)** O salto principal de assertividade ocorre entre L2 e L3 — isto é, ao fornecer fatores de caracterização adequados ao escopo regional. A partir de L3, a concordância operacional ($< 30\%$ de erro) é atingida pela maioria dos LLMs avaliados; em L4 (procedimento explícito), todos atingem 100% de concordância. **(iii)** Em ausência de instrução, os três LLMs convergem para modelos mainstream globais (ReCiPe 2016, IMPACT World+) e nenhum seleciona espontaneamente o modelo nativamente regionalizado para o Brasil — reforçando a lacuna L3 da literatura.

Implicações para uso responsável: praticantes que desejam empregar LLMs em estudos de ACV regionalizada devem fornecer minimamente o inventário e os fatores de caracterização,

sob pena de viés de generalização global. O protocolo experimental aqui validado é replicável e pode servir como diretriz mínima de prompt para auditoria de uso de IA em ACV. Como limitação, este resumo restringe-se a um sistema produtivo e a um modelo de caracterização; a extensão para a matriz completa (4 sistemas $\times$ 5 modelos $\times$ 3 escopos) será apresentada em trabalho subsequente.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental avaliação do ciclo de vida princípios e estrutura. Rio de Janeiro: ABNT, 2009.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental avaliação do ciclo de vida requisitos e orientações. Rio de Janeiro: ABNT, 2009.

BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.

GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.

GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.

HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.

OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.