TESTE DE CONTAMINAÇÃO EM LLMS APLICADOS À ACV REGIONALIZADA DO MATERIAL PARTICULADO EM PRODUÇÃO LEITEIRA

Lucas Rover
Universidade Tecnológica Federal do Paraná (UTFPR)
lucasrover@alunos.utfpr.edu.br
Gabriela Giusti
Universidade Federal de São Carlos (UFSCar)
gabriela.giusti@hotmail.com.br
Daiane Vitória da Silva
Universidade Federal de São Carlos (UFSCar)
Diogo Aparecido Lopes Silva
Universidade Federal de São Carlos (UFSCar)
diogo.apls@ufscar.br
Yara de Souza Tadano
Universidade Tecnológica Federal do Paraná (UTFPR)
yaratadano@utfpr.edu.br

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs, do inglês *Large Language Models*) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já usam essas ferramentas para estimar fatores, revisar inventários e gerar análises, geralmente sem protocolo padronizado ou quantificação do erro.

A literatura consultada não encontrou estudos que testem sistematicamente estimativas de LLMs contra ACVs auditadas, regionalizadas e com controle de contaminação. Esse vazio é problemático: saídas de LLMs são fluentes mesmo quando incorretas (JI *et al.*, 2023), e os modelos memorizam dados de treinamento e os reproduzem na inferência (CARLINI *et al.*, 2023; SAINZ *et al.*, 2023; ROVER *et al.*, 2026). Categorias de impacto sensíveis a condições locais — como a formação de material particulado (MP) (GIUSTI *et al.*, 2023) — ainda são tipicamente avaliadas com fatores de caracterização (FCs) globais, dado que abordagens regionalizadas para o Brasil são recentes, como o modelo de OBERSCHELP *et al.* (2020), recomendado pelo *Global LCIA Guidance* (GLAM) (LIFE CYCLE INITIATIVE, 2024). Falta evidência empírica sobre se os LLMs incorporam essa regionalização.

A pergunta de pesquisa é: em que ponto da escala de enriquecimento de prompt o LLM passa a produzir uma estimativa de ACV confiável considerando a categoria formação de material particulado?

2 METODOLOGIA

2.1 ARTIGO-REFERÊNCIA E *GROUND TRUTH*

Realizou-se um recorte dos estudos de caso de Giusti *et al.* (2023). Foram selecionados dois sistemas brasileiros de produção leiteira que representam perfis extremos no estudo

original: um confinado típico em São Paulo (S1) e um semi-intensivo no Paraná (S2). Avaliou-se na perspectiva *cradle-to-farm gate* (ABNT NBR ISO 14040, 2009; ABNT NBR ISO 14044, 2009), com unidade funcional de 1 kg FPCM (*fat-and-protein corrected milk*). Adotou-se o modelo de Oberschelp *et al.* (2020) com efeito *Average* no nível do solo, considerando os três níveis de regionalização disponibilizados pelos autores (global, nacional e estadual), e alocação econômica. A reconciliação do *ground truth* partiu do material suplementar de Oberschelp e da planilha pública de Giusti (discrepância $< 0{,}1\%$). Resulta um *ground truth* de seis células em DALY/kg FPCM (*Disability-Adjusted Life Years*; Tabela 1).

Tabela 1 – *Ground truth* — Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	**Sistema 1 (SP)**	**Sistema 2 (PR)**
Global	$2{,}830 \times 10^{-8}$	$1{,}281 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$	$1{,}096 \times 10^{-7}$
Estado-alvo	$6{,}373 \times 10^{-7}$	$1{,}554 \times 10^{-7}$
Razão Estado/Global	$22{,}5\times$	$12{,}1\times$

Nota: razões distintas refletem perfis de emissão diferentes por sistema e estados-alvo distintos. Fonte: elaborada pelos autores a partir de Giusti *et al.* (2023) e Oberschelp *et al.* (2020).

2.2 VARIÁVEL INDEPENDENTE: NÍVEIS DE ENRIQUECIMENTO DE PROMPT

Cinco níveis ordenados (L0–L4) foram desenhados, cada um adicionando uma dimensão de informação ao anterior: L0 (apenas a pergunta); L1 (escopo ISO 14040/14044); L2 (inventário compilado dos 28 fluxos elementares relevantes à formação de MP no Sistema 1); L3 (tabela trabalhada de FCs de Oberschelp *et al.* (2020) para os três níveis de regionalização); L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, em que I_g é o impacto no escopo g, m_i a massa do fluxo i e $CF_{i,g}$ o respectivo fator de caracterização). ICV e planilha de FCs foram disponibilizados em versão trabalhada, contendo apenas variáveis necessárias ao cálculo. A formulação de L4 segue a lógica de *chain-of-thought prompting* (WEI *et al.*, 2022).

2.3 MODELOS LLM E DESENHO EXPERIMENTAL

Foram avaliados três LLMs: GPT-4.1 (OpenAI, `gpt-4.1-2025-04-14`; ACHIAM *et al.*, 2023), Gemini 2.5 Pro (Google; GEMINI TEAM, 2025) e DeepSeek V3 (DEEPSEEK-AI, 2024). Para cada sistema, cada combinação LLM $\times$ nível (L0–L4) $\times$ idioma (português brasileiro — PT-BR; inglês — EN) foi replicada $n = 5$ vezes, sob temperatura nula ($T = 0$) e *seed* 42. APIs proprietárias podem apresentar não-determinismo residual mesmo sob $T = 0$ (ROVER *et al.*, 2026); o Gemini não expõe *seed*, e sua estabilidade foi verificada *a posteriori* pelo coeficiente de variação (CV) intra-célula em L3/L4 ($\leq 0{,}003$). *System prompt*, nota experimental e esquema JSON estão no Material Complementar[1]. No experimento principal foram registradas 300 chamadas; somadas às 180 do teste de contaminação, o estudo totaliza 480 chamadas.

[1]Material Complementar e *scripts*: `https://github.com/Roverlucas/ia-acv-gcv2026`.

2.4 MÉTRICAS E ANÁLISE

Para cada chamada foram computados o erro relativo absoluto e o erro percentual médio absoluto (MAPE, *Mean Absolute Percentage Error*), a aderência metodológica (modelo de FC e alocação declarados) e a sensibilidade regional; a estabilidade foi avaliada por taxa de não-resposta, conformidade ao esquema JSON e CV intra-célula entre repetições. Dois limiares foram fixados *a priori*. O de 30% é o critério operacional de concordância e corresponde à ordem de grandeza da divergência entre os modelos de caracterização recomendados para o Brasil por Giusti *et al.* (2022), abaixo da qual a estimativa não alteraria a conclusão comparativa de um estudo. O de 10% separa cálculo de reprodução no teste de contaminação (seção 2.5) e é duas ordens de grandeza maior que o CV intra-célula observado em L3/L4 ($\leq 0{,}003$), de modo que a classificação não é sensível ao ruído do próprio modelo.

2.5 CONTROLE DE CONTAMINAÇÃO POR TREINAMENTO

O artigo-referência foi publicado em 2023, anterior ao *cutoff* de treinamento dos LLMs avaliados, o que abre a hipótese de memorização (CARLINI *et al.*, 2023). Para discriminar memorização de cálculo, replicou-se L3 e L4 em PT-BR ($n = 5$) com três esquemas de inventário perturbado por sistema (massas $\times$ 2; amônia $\times$ 0,1; cada substância $\times$ U[0,5; 2,0] com *seed* fixa), em 180 chamadas adicionais. O prompt traz nota experimental explícita informando que o inventário é hipotético. Cada chamada produz dois erros: Δ_{novo} contra o *ground truth* recalculado e Δ_{orig} contra o valor publicado. Classifica-se como *cálculo* se $|\Delta_{\text{novo}}| < 10\%$ e como *memorização* se $|\Delta_{\text{orig}}| < 10\%$; *misto* quando nenhum critério é satisfeito e *null* quando há recusa numérica. O termo memorização é empregado em sentido operacional — reproduzir o valor publicado apesar de dados de entrada alterados — e não no sentido estrito de extração *verbatim* de dado de treino (CARLINI *et al.*, 2023), cuja verificação exigiria acesso aos corpora.

3 RESULTADOS

Das 300 chamadas do experimento principal, 297 retornaram JSON conforme o esquema (3 falhas de *parsing* em DeepSeek L4 EN). A taxa de resposta numérica não-`null` variou por nível e por LLM, com o GPT apresentando recusa sistemática em níveis com informação insuficiente.

3.1 CURVA DE SATURAÇÃO MAPE $\times$ NÍVEL

A Figura 1 apresenta a mediana e o intervalo interquartil do erro relativo absoluto por nível, LLM e idioma. À primeira vista, o salto principal de acurácia ocorre entre L2 e L3 e o erro cai a valores próximos de zero em L3 e L4. Essa aparente convergência é, no entanto, o sintoma central deste trabalho (seção 3.4): ela é produto de memorização do artigo-referência, não de cálculo.

3.2 COMPORTAMENTO METODOLÓGICO (MODELO DECLARADO)

Em L0–L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), recomendado para o Brasil pelo GLAM (LIFE CYCLE INITIATIVE, 2024). GPT e Gemini citaram ReCiPe 2016 (HUIJBREGTS *et al.*, 2017), baseado em Van Zelm *et al.* (2016), e DeepSeek citou IMPACT World+ (BULLE *et al.*, 2019), regionalizado para a América Latina mas sem o detalhamento estadual de Oberschelp ou de Fantke *et al.* (2019). Os LLMs tendem, portanto, a recorrer a FCs de métodos já consolidados em *softwares* de AICV, e não a modelos publicados em artigos ainda não integrados a ferramentas, mesmo havendo recomendação do GLAM e de Giusti *et al.* (2022). A partir

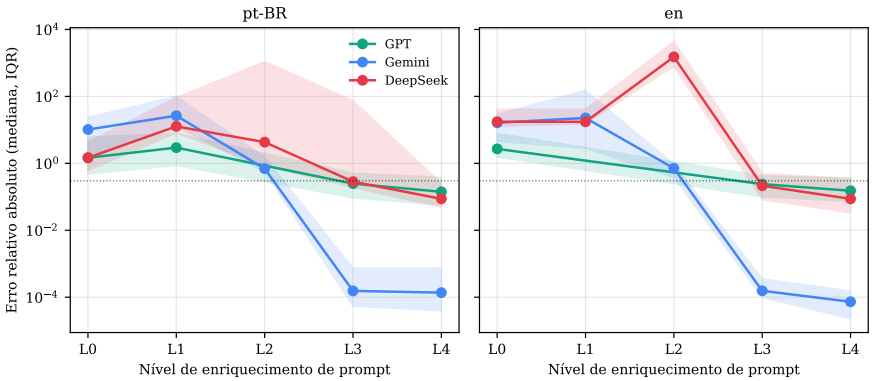


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) por nível de enriquecimento de prompt, LLM e idioma (português brasileiro — pt-BR; inglês — en). Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%. Fonte: elaborada pelos autores.

de L3, todos seguiram a instrução, confirmando a recomendação de Heijungs e Dekker (2022) de explicitar o modelo escolhido.

3.3 CONCORDÂNCIA OPERACIONAL

A fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto é nula ou marginal em L0–L2 em quase todas as células. Em L3, GPT e Gemini atingem 100% em ambos os idiomas, enquanto DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4, todos os três LLMs atingem 100%.

3.4 ACHADO CENTRAL: MEMORIZAÇÃO VS. CÁLCULO

A razão Estado/Global publicada é 22,5× (S1) e 12,1× (S2); em L0–L2, os três LLMs reportam razões entre 1,0× e 3,0×. Em L3–L4, o Gemini reproduz a razão exata (22,52× e 12,13×); GPT e DeepSeek aproximam-se (±10–60%). O GPT retornou `null` em 100% das chamadas de L2 e em L1 EN, justificando ausência de FCs suficientes. Essa recusa merece leitura distinta: abster-se quando os dados não sustentam o cálculo é comportamento preferível à alucinação ativa, e enquanto Gemini e DeepSeek estimaram valores em L0–L2 com erros de até duas ordens de grandeza, o GPT sinalizou o limite da própria informação. Em ACV, onde um número errado alimenta declarações ambientais indevidas, não responder é cientificamente superior a responder com fluência infundada.

O teste de contaminação (Tabela 2) mostra que o Gemini reproduziu o *ground truth* com erro $< 0{,}5\%$ e CV nulo em L3/L4 e, sob inventário perturbado, classifica-se como memorização em 29 de 30 chamadas em cada sistema. O GPT memoriza S1 (27/30) e quase nunca S2 (3/30, com 27 *mistas*); DeepSeek apresenta o menor padrão (13/30 em S1; 0/30 em S2). A nota experimental no prompt não alterou o resultado.

O padrão é assimétrico entre sistemas: GPT e DeepSeek reproduzem o valor publicado em S1, mas quase nunca em S2. Uma explicação plausível é a densidade desigual dos casos nos corpora de treinamento. O sistema confinado paulista é o perfil mais recorrente na literatura de ACV leiteira brasileira, enquanto sistemas pastoris sulistas aparecem com menos frequência, de modo que o desequilíbrio amostral da própria produção científica seria herdado pelos corpora. Se essa leitura se confirmar, o viés geográfico da pesquisa em sustentabilidade se propaga para as ferramentas que passam a mediá-la, e regiões menos estudadas ficam sujeitas a estimativas menos ancoradas justamente onde a regionalização mais importa.

O nível L4 entrega o procedimento de cálculo de forma explícita, sob a lógica de

chain-of-thought prompting (WEI *et al.*, 2022), e ainda assim o Gemini reproduziu o valor publicado em 29 das 30 chamadas com inventário perturbado. O modelo ignorou os números fornecidos no prompt para devolver o resultado estocado durante o pré-treinamento, isto é, a contaminação anula a cadeia de raciocínio em vez de ser corrigida por ela. Engenharia de prompt, portanto, não é garantia de confiabilidade quando o caso de teste já está no corpus.

Tabela 2 – Teste de contaminação: classificação das chamadas L3+L4 PT-BR ($n = 30$ por LLM por sistema)

	Sistema 1 (SP)				Sistema 2 (PR)			
LLM	Calc.	Mem.	Misto	Null	Calc.	Mem.	Misto	Null
GPT	0	27	3	0	0	3	27	0
Gemini	1	29	0	0	1	29	0	0
DeepSeek	1	13	15	1	4	0	21	5

Legenda: Calc. = cálculo ($|\Delta_{\text{novo}}| < 10\%$); Mem. = memorização ($|\Delta_{\text{orig}}| < 10\%$); Misto = nenhum dos critérios; Null = recusa numérica. IC_{95} (Clopper–Pearson) da taxa de memorização — S1: GPT [0,73; 0,98], Gemini [0,83; 1,00], DeepSeek [0,25; 0,63]; S2: GPT [0,02; 0,27], Gemini [0,83; 1,00], DeepSeek [0,00; 0,12]. Fonte: elaborada pelos autores.

A diferença Gemini–DeepSeek é amparada por intervalos de confiança 95% (Clopper–Pearson) não-sobrepostos em ambos os sistemas (Tabela 2); a sensibilidade ao limiar preserva o ordenamento (em $\pm 5\%$, GPT-S1 cai para 22/30; em $\pm 15\%$, sobe para 29/30). Em L0–L2 o CV intra-célula chegou a 1,2 no Gemini, com estimativas diferindo em até uma ordem de grandeza entre repetições mesmo sob $T = 0$.

3.5 LIMITAÇÕES

O desenho cobre dois sistemas, um modelo de caracterização e três LLMs, o que restringe a generalização a outros produtos, categorias de impacto e famílias de modelos. Com $n = 5$ por célula, suficiente para modelos determinísticos sob $T = 0$, não cabem testes inferenciais, e as comparações permanecem descritivas. A memorização é inferida do comportamento sob perturbação, não verificada na fonte: sem acesso aos corpora de treinamento, não se descarta que parte das respostas decorra de ancoragem em valores plausíveis da literatura, ainda que a reprodução do valor exato com CV nulo torne essa alternativa pouco provável. Por fim, APIs proprietárias são atualizadas e depreciadas sem aviso, e a réplica exata deste teste depende da permanência das versões avaliadas, o que reforça o argumento de Rover *et al.* (2026) sobre o não-determinismo oculto dessas interfaces.

4 CONCLUSÕES

A acurácia aparente dos LLMs em L3 e L4 vem da reprodução do artigo-referência, não de cálculo: sob inventário perturbado, 58/60 chamadas do Gemini, 27/30 do GPT no Sistema 1 e 13/30 do DeepSeek no Sistema 1 reportam o valor publicado ignorando os dados fornecidos. O gradiente Gemini $\rightarrow$ GPT $\rightarrow$ DeepSeek e a assimetria entre os Sistemas 1 e 2 sugerem que o artigo-referência chegou aos corpora em doses distintas.

No uso informal típico (L0–L1), os erros variam de 2 a 273 vezes o valor publicado e nenhum LLM seleciona o modelo recomendado pelo GLAM, o que subestima a diferenciação regional em uma a duas ordens de grandeza.

No escopo avaliado, nenhum comportamento observado satisfaz os requisitos de uma ACV regionalizada tal qual apresentada em Giusti *et al.* (2023). Disso decorre uma

recomendação metodológica explícita para a comunidade de ACV: **LLMs não devem ser empregados como motores de cálculo de impacto** (AICV). Quando acertam, não é por cálculo, e o acerto desaparece assim que o caso sai do que foi memorizado — exatamente a situação de qualquer estudo novo. O papel seguro dessas ferramentas está nas etapas de processamento de linguagem natural, como a extração e a conversão de inventários textuais não estruturados para formatos legíveis por máquina, a exemplo do esquema JSON avaliado neste trabalho, delegando a caracterização regional e a álgebra de matrizes a sistemas determinísticos. Como mitigação parcial, *retrieval-augmented generation* ancorado em tabelas de FCs verificadas mantém o modelo na função de interface, e não de calculadora. A matriz completa (4 sistemas $\times$ 5 modelos $\times$ 3 escopos) será apresentada em trabalho subsequente.

Conflito de interesse. Gabriela Giusti e Yara de Souza Tadano são autoras do artigo-referência Giusti *et al.* (2023), utilizado como *ground truth*. A comparação foi feita contra números publicados, sem reanálise do dado bruto. Repositório: `https://github.com/Roverlucas/ia-acv-gcv2026`.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.
ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental — avaliação do ciclo de vida — princípios e estrutura. Rio de Janeiro: ABNT, 2009.
ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental — avaliação do ciclo de vida — requisitos e orientações. Rio de Janeiro: ABNT, 2009.
BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.
BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.
CARLINI, N. *et al.* Quantifying memorization across neural language models. In: **International Conference on Learning Representations** (ICLR), 2023.
DEEPSEEK-AI. DeepSeek-V3 Technical Report. **arXiv preprint**, arXiv:2412.19437, 2024.
FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.
GEMINI TEAM. Gemini 2.5: pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. **Google DeepMind Technical Report**, 2025.
GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.
GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.
HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.
HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.
JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.
LIFE CYCLE INITIATIVE. **GLAM — Global Guidance for LCIA Indicators and Methods**. UNEP Life Cycle Initiative, 2024. Disponível em: `https://www.lifecycleinitiative.org/activities/`. Acesso em: 21 out. 2024.
OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.
ROVER, L. *et al.* Same prompt, different answer: hidden non-determinism in LLM APIs undermines scientific reproducibility. **Nature Communications** (em revisão), 2026. DOI: 10.6084/m9.figshare.31653373.
SAINZ, O. *et al.* NLP evaluation in trouble: on the need to measure LLM data contamination for each benchmark. In: **Findings of EMNLP**, 2023.
VAN ZELM, R. *et al.* Regionalized human health characterization factors for particulate matter exposure for use in life cycle assessment. **Atmospheric Environment**, v. 134, p. 213–220, 2016.
WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.