ACURÁCIA DE LLMS EM ESTUDOS DE ACV REGIONALIZADA: EFEITO DO ENRIQUECIMENTO CONTEXTUAL DO PROMPT EM ESTIMATIVAS DO IMPACTO DO MATERIAL PARTICULADO

[Identificação dos autores omitida para revisão por pares]

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já usam essas ferramentas para estimar fatores ausentes, revisar inventários e gerar análises a partir de descrições em linguagem natural, sem protocolo de uso, sem rotina de auditoria e sem medida quantitativa de erro associada a essa prática.

Três lacunas convergentes motivam este trabalho. Primeiro, não há estudos publicados que comparem estimativas de LLMs com ACVs auditadas e regionalizadas. Segundo, saídas de LLMs são fluentes mesmo quando o conteúdo numérico ou citacional é incorreto, fenômeno descrito por JI *et al.* (2023) como alucinação. Terceiro, a regionalização de impactos central para o caso brasileiro de material particulado (MP) em saúde humana (GIUSTI *et al.*, 2022, 2023) costuma ser substituída por fatores genéricos globais quando se consulta o modelo sem dados específicos. A pergunta operacional decorrente é: **em que ponto da escala de enriquecimento contextual do prompt o LLM passa a produzir uma estimativa de ACV utilizável?** Este resumo apresenta um desenho experimental que responde a essa pergunta tomando como referência a ACV regionalizada de Giusti *et al.* (2023) para sistemas leiteiros brasileiros.

2 METODOLOGIA

2.1 Paper-referência e *ground truth*

O estudo de Giusti *et al.* (2023) analisa quatro sistemas de produção leiteira brasileiros (*cradle-to-farm gate*; ABNT NBR ISO 14040 e 14044, 2009), com unidade funcional de 1 kg FPCM (*fat-and-protein corrected milk*), e aplica cinco modelos de caracterização com três níveis de regionalização. Para este resumo, fixamos o Sistema 1 (sistema confinado típico), o modelo de caracterização de OBERSCHELP *et al.* (2020) com modelo de efeito *Average* a nível do solo, e a alocação econômica. Disso resulta um *ground truth* de três células de impacto em DALY/kg FPCM (Tabela 1). Os fatores de caracterização nativos foram extraídos do material suplementar do paper de Oberschelp e reconciliados com a planilha de cálculo de Giusti *et al.* (2023); a discrepância máxima foi inferior a 0,1%.

Tabela 1 – Ground truth Sistema 1, Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	Impacto (DALY/kg FPCM)
Global	$2{,}830 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$
Estado de São Paulo	$6{,}373 \times 10^{-7}$

Razão SP/Global $\approx 22{,}5\times$, reflexo da maior densidade populacional e maior fração de emissões em compartimento urbano no estado.

2.2 Variável independente níveis de enriquecimento de prompt

Cinco níveis ordenados foram desenhados, cada um adicionando uma dimensão de informação ao anterior: L0 (apenas a pergunta), L1 (escopo ISO 14040/14044), L2 (inventário agregado de 28 fluxos PM-relevantes do Sistema 1, selecionados conforme o subconjunto de poluentes do modelo Oberschelp), L3 (tabela de fatores de caracterização Oberschelp para os três escopos) e L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, no espírito de *chain-of-thought prompting*, WEI *et al.*, 2022).

2.3 Modelos LLM e desenho experimental

Foram avaliados três modelos LLM de fronteira: GPT (OpenAI, versão `gpt-4.1-2025-04-14`), Gemini 2.5 Pro (Google, `gemini-2.5-pro`) e DeepSeek V3 (`deepseek-chat`, via API). Cada combinação *LLM* $\times$ *nível* $\times$ *idioma (PT-BR, EN)* foi replicada $n = 5$ vezes, com temperatura fixada em 0 e *seed* igual a 42 (OpenAI e DeepSeek; Gemini não expõe *seed* na API). O *system prompt* exigiu resposta em JSON estrito (esquema canônico, registrado no repositório), com regras explícitas contra fabricação de valores e de referências. Total: 150 chamadas, custo de US$ 1,71 e tempo de execução de 54 min. Prompts, respostas brutas e scripts de análise são compartilhados em repositório público anonimizado.

2.4 Métricas e análise

Foram computadas quatro famílias de métricas: erro numérico (erro relativo absoluto, MAPE e log-razão $\log_{10}(\hat{I}/I_{GT})$); aderência metodológica (modelo de caracterização e método de alocação declarados); sensibilidade regional (presença de diferenciação entre os três escopos); e estabilidade do output (taxa de não-resposta, conformidade ao esquema JSON, coeficiente de variação intra-célula entre as repetições). O critério operacional de concordância é erro relativo absoluto $< 30\%$. Como limitação reconhecida, $n = 5$ por célula é suficiente para LLMs determinísticos sob $T = 0$ mas não permite testes inferenciais robustos; comparações usam estatística descritiva.

2.5 Controle de validade

O paper-referência foi publicado em 2023, anterior ao *cutoff* de treinamento dos LLMs avaliados, abrindo a possibilidade de memorização do resultado em vez de cálculo. Um teste com inventário e fatores perturbados está em execução e será reportado em trabalho subsequente. Conflito de interesse: a versão final declarará vínculo entre autoria e paper-referência; toda comparação foi feita contra números publicados, sem reanálise privilegiada do dado bruto.

3 RESULTADOS

As 150 chamadas retornaram JSON estritamente conforme o esquema. A taxa de resposta numérica não-`null` variou por nível e por LLM, com o GPT apresentando recusa sistemática em níveis com informação insuficiente.

3.1 Curva de saturação MAPE $\times$ nível

A Figura 1 apresenta a mediana e o intervalo interquartil do erro relativo absoluto por nível, LLM e idioma. O salto principal de acurácia ocorre entre L2 e L3 quando o prompt passa a incluir os fatores de caracterização e o erro cai para valores próximos de zero em L3 e L4 nos três LLMs. A Tabela 2 consolida os valores médios.

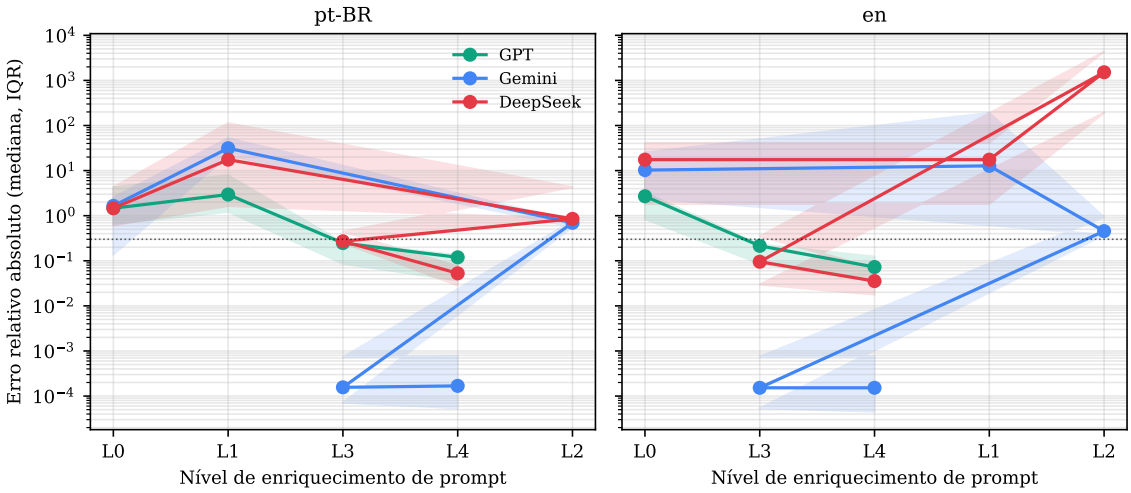


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) por nível de enriquecimento de prompt, LLM e idioma. Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%.

Tabela 2 – MAPE por LLM × idioma × nível (média sobre 3 escopos × 5 reps).

LLM	Idioma	L0	L1	L2	L3	L4
GPT	PT-BR	+2.5×	+3.9×	—	+20%	+11%
GPT	EN	+2.5×	—	—	+17%	+7%
Gemini	PT-BR	+5.8×	+273.2×	+2.6×	+0%	+0%
Gemini	EN	+16.9×	+110.0×	+65%	+0%	+0%
DeepSeek	PT-BR	+2.1×	+89.4×	+2.2×	+32%	+5%
DeepSeek	EN	+20.2×	+20.2×	+2017.9×	+15%	+5%

Erro relativo absoluto médio (MAPE). Valores apresentados em % até 100%; acima disso, em múltiplos do GT (×).

3.2 Comportamento metodológico (modelo declarado)

Em L0L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), apesar de ser o modelo nativamente regionalizado para o Brasil. As escolhas dividiram-se entre ReCiPe 2016 (HUIJBREGTS *et al.*, 2017), citado predominantemente por GPT e Gemini, e IMPACT World+ (BULLE *et al.*, 2019), citado predominantemente por DeepSeek (Tabela 3). A partir de L3, com o modelo indicado no prompt, todos seguiram a instrução (29 de 30 respostas em L3 e L4 em PT-BR). Esse padrão é consistente com a recomendação de HEIJUNGS & DEKKER (2022) de explicitar o modelo de caracterização em meta-comparações e com a limitação prática de modelos globais (e.g., FANTKE *et al.*, 2019) frente a aplicações regionalizadas.

Tabela 3 – Modelo de caracterização declarado pelas LLMs por nível (PT-BR, contagem agregada).

Nível	Oberschelp	Recipe	Impact World	Other	Unspecified
L0	0	9	6	0	0
L1	0	10	5	0	0
L2	0	5	5	5	0
L3	14	0	0	0	1
L4	15	0	0	0	0

3.3 Concordância operacional

A Figura 2 reporta a fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto. Em L0L2 essa fração é nula ou marginal em quase todas as células. Em L3, GPT e Gemini atingem 100% em ambos os idiomas, e DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4, com fórmula explícita, os três LLMs atingem 100%.

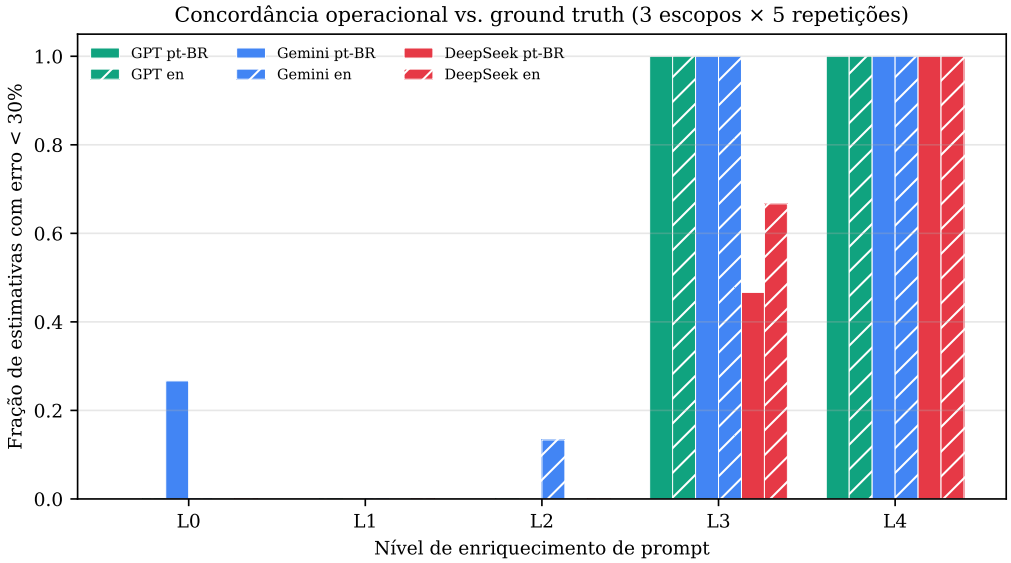


Figura 2 – Fração de estimativas com erro relativo absoluto $< 30\%$ (critério operacional de concordância).

3.4 Achados qualitativos

Recusa defensiva do GPT. O GPT retornou `null` em 100% das 10 chamadas de L2 e em 100% das 5 chamadas de L1 em EN, justificando explicitamente a ausência de fatores de caracterização como impeditivo do cálculo. Esse comportamento é replicável e consistente com a calibração de recusa documentada em GPT-4 (ACHIAM *et al.*, 2023).

Reprodutibilidade do Gemini em L3 e L4. Em 60 chamadas (5 repetições $\times$ 3 escopos $\times$ 2 idiomas $\times$ 2 níveis), o Gemini reproduziu o *ground truth* com erro relativo inferior a 0,5% e coeficiente de variação intra-célula nulo. GPT (CV $\sim$0,080,10) e DeepSeek (CV $\sim$0,02) também se aproximaram do *ground truth* em L4, com variância maior. A possibilidade de contaminação do corpus de treinamento pelo paper-referência (publicado em 2023) é abordada na próxima seção como limitação.

Variância em L0L2. O coeficiente de variação intra-célula em L0L2 chegou a 1,2 no Gemini, com estimativas diferindo em até uma ordem de grandeza entre repetições mesmo sob $T = 0$.

4 CONCLUSÕES

Para o caso testado (PM em sistema leiteiro confinado brasileiro, modelo Oberschelp, alocação econômica), a acurácia das estimativas depende fortemente da informação contextual entregue ao prompt. Em L0 e L1, os erros típicos foram de 2 a 273 vezes o *ground truth*; em L4, os três LLMs reproduziram o resultado dentro de 11% (Gemini abaixo de 0,5%). O salto principal ocorre entre L2 e L3, ao entregar ao modelo os fatores de caracterização adequados ao escopo regional. L4 confirma que LLMs executam corretamente a aritmética da ACV quando o prati-

cante já fez o trabalho metodológico; o achado substantivo é o fracasso sistemático em L0L2, faixa que corresponde ao uso informal típico.

Sem instrução explícita, os três LLMs escolheram ReCiPe 2016 ou IMPACT World+ e nenhum acionou espontaneamente o modelo Oberschelp regionalizado para o Brasil. A extensão para a matriz completa do paper-referência (4 sistemas $\times$ 5 modelos $\times$ 3 escopos) e o teste de contaminação serão apresentados em trabalho subsequente.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental avaliação do ciclo de vida princípios e estrutura. Rio de Janeiro: ABNT, 2009.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental avaliação do ciclo de vida requisitos e orientações. Rio de Janeiro: ABNT, 2009.

BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.

BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.

FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.

GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.

GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.

HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.

HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.

JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.

OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.

WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.