ACURÁCIA DE LLMS EM ESTUDOS DE ACV REGIONALIZADA: EFEITO DO ENRIQUECIMENTO CONTEXTUAL DO PROMPT EM ESTIMATIVAS DO IMPACTO DO MATERIAL PARTICULADO

[Identificação dos autores omitida para revisão por pares]

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já usam essas ferramentas para estimar fatores ausentes, revisar inventários e gerar análises a partir de descrições em linguagem natural, sem protocolo de uso, sem rotina de auditoria e sem medida quantitativa de erro associada a essa prática.

Três lacunas convergentes motivam este trabalho. Primeiro, não há estudos publicados que comparem estimativas de LLMs com ACVs auditadas e regionalizadas. Segundo, saídas de LLMs são fluentes mesmo quando o conteúdo numérico ou citacional é incorreto, fenômeno descrito por JI *et al.* (2023) como alucinação. Terceiro, a regionalização de impactos central para o caso brasileiro de material particulado (MP) em saúde humana (GIUSTI *et al.*, 2022, 2023) costuma ser substituída por fatores genéricos globais quando se consulta o modelo sem dados específicos. A pergunta operacional decorrente é: **em que ponto da escala de enriquecimento contextual do prompt o LLM passa a produzir uma estimativa de ACV utilizável?** Este resumo apresenta um desenho experimental que responde a essa pergunta tomando como referência a ACV regionalizada de Giusti *et al.* (2023) para sistemas leiteiros brasileiros.

2 METODOLOGIA

2.1 Paper-referência e *ground truth*

O estudo de Giusti *et al.* (2023) analisa quatro sistemas de produção leiteira brasileiros (*cradle-to-farm gate*; ABNT NBR ISO 14040 e 14044, 2009), com unidade funcional de 1 kg FPCM (*fat-and-protein corrected milk*), e aplica cinco modelos de caracterização com três níveis de regionalização. Para este resumo, fixamos o Sistema 1 (sistema confinado típico), o modelo de caracterização de OBERSCHELP *et al.* (2020) com modelo de efeito *Average* a nível do solo, e a alocação econômica. Disso resulta um *ground truth* de três células de impacto em DALY/kg FPCM (Tabela 1). Os fatores de caracterização nativos foram extraídos do material suplementar do paper de Oberschelp e reconciliados com a planilha de cálculo de Giusti *et al.* (2023); a discrepância máxima foi inferior a 0,1%.

Tabela 1 – Ground truth Sistema 1, Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	Impacto (DALY/kg FPCM)
Global	$2{,}830 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$
Estado de São Paulo	$6{,}373 \times 10^{-7}$

Razão SP/Global $\approx 22{,}5\times$, reflexo da maior densidade populacional e maior fração de emissões em compartimento urbano no estado.

2.2 Variável independente níveis de enriquecimento de prompt

Cinco níveis ordenados foram desenhados, cada um adicionando uma dimensão de informação ao anterior: L0 (apenas a pergunta), L1 (escopo ISO 14040/14044), L2 (inventário agregado de 28 fluxos PM-relevantes do Sistema 1, selecionados conforme o subconjunto de poluentes do modelo Oberschelp), L3 (tabela de fatores de caracterização Oberschelp para os três escopos) e L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, no espírito de *chain-of-thought prompting*, WEI *et al.*, 2022).

2.3 Modelos LLM e desenho experimental

Foram avaliados três modelos LLM de fronteira: GPT (OpenAI, versão `gpt-4.1-2025-04-14`), Gemini 2.5 Pro (Google, `gemini-2.5-pro`) e DeepSeek V3 (`deepseek-chat`, via API). Cada combinação *LLM* $\times$ *nível* $\times$ *idioma (PT-BR, EN)* foi replicada $n = 5$ vezes, com temperatura fixada em 0 e *seed* igual a 42 (OpenAI e DeepSeek; Gemini não expõe *seed* na API). O *system prompt* exigiu resposta em JSON estrito (esquema canônico, registrado no repositório), com regras explícitas contra fabricação de valores e de referências. Total: 150 chamadas, custo de US$ 1,71 e tempo de execução de 54 min. Prompts, respostas brutas e scripts de análise são compartilhados em repositório público anonimizado.

2.4 Métricas e análise

Foram computadas quatro famílias de métricas: erro numérico (erro relativo absoluto, MAPE e log-razão $\log_{10}(\hat{I}/I_{GT})$); aderência metodológica (modelo de caracterização e método de alocação declarados); sensibilidade regional (presença de diferenciação entre os três escopos); e estabilidade do output (taxa de não-resposta, conformidade ao esquema JSON, coeficiente de variação intra-célula entre as repetições). O critério operacional de concordância é erro relativo absoluto $< 30\%$. Como limitação reconhecida, $n = 5$ por célula é suficiente para LLMs determinísticos sob $T = 0$ mas não permite testes inferenciais robustos; comparações usam estatística descritiva.

2.5 Controle de contaminação por treinamento

O paper-referência foi publicado em 2023, anterior ao *cutoff* de treinamento dos LLMs, abrindo a hipótese de memorização em vez de cálculo. Para discriminar as duas, replicamos L3 e L4 em PT-BR ($n = 5$) com três esquemas de inventário perturbado: P1 (massas $\times$ 2; novo GT $= 2\times$ original); P2 (amônia $\times$ 0,1; novo GT $\approx 0{,}37\times$ original); P3 (cada substância $\times$ U[0,5; 2,0], seed fixa). O prompt traz nota experimental explícita informando que o inventário é hipotético. Classifica-se a chamada como *cálculo* se erro contra o novo GT $< 10\%$ e como *memorização* se erro contra o GT original $< 10\%$. Conflito de interesse: a versão final declarará vínculo entre autoria e paper-referência.

3 RESULTADOS

As 150 chamadas retornaram JSON estritamente conforme o esquema. A taxa de resposta numérica não-`null` variou por nível e por LLM, com o GPT apresentando recusa sistemática em níveis com informação insuficiente.

3.1 Curva de saturação MAPE $\times$ nível

A Figura 1 apresenta a mediana e o intervalo interquartil do erro relativo absoluto por nível, LLM e idioma. O salto principal de acurácia ocorre entre L2 e L3 quando o prompt passa a

incluir os fatores de caracterização e o erro cai para valores próximos de zero em L3 e L4 nos três LLMs. A Tabela 2 consolida os valores médios.

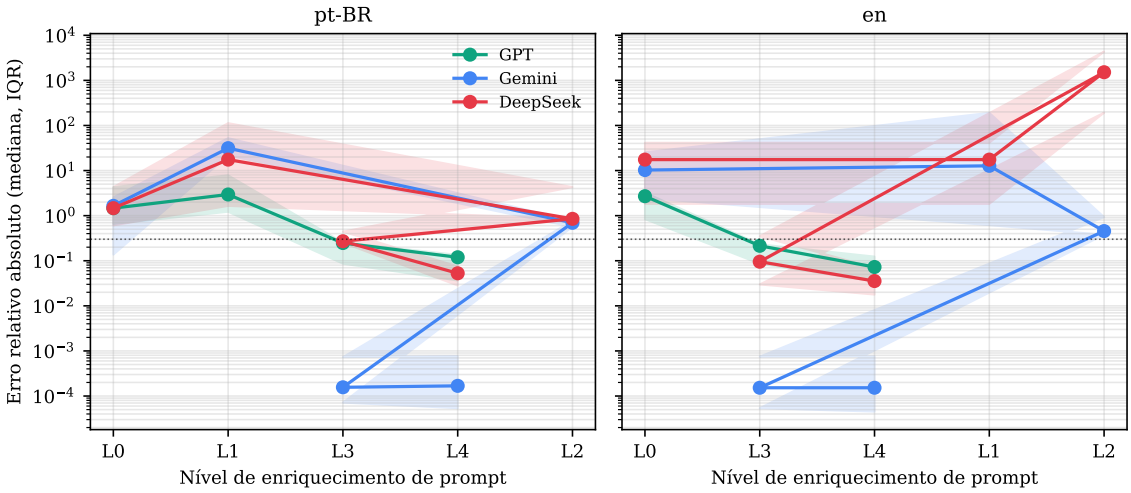


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) por nível de enriquecimento de prompt, LLM e idioma. Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%.

Tabela 2 – MAPE por LLM × idioma × nível (média sobre 3 escopos × 5 reps).

LLM	Idioma	L0	L1	L2	L3	L4
GPT	PT-BR	+2.5×	+3.9×	—	+20%	+11%
GPT	EN	+2.5×	—	—	+17%	+7%
Gemini	PT-BR	+5.8×	+273.2×	+2.6×	+0%	+0%
Gemini	EN	+16.9×	+110.0×	+65%	+0%	+0%
DeepSeek	PT-BR	+2.1×	+89.4×	+2.2×	+32%	+5%
DeepSeek	EN	+20.2×	+20.2×	+2017.9×	+15%	+5%

Erro relativo absoluto médio (MAPE). Valores apresentados em % até 100%; acima disso, em múltiplos do GT (×).

3.2 Comportamento metodológico (modelo declarado)

Em L0L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), apesar de ser o modelo nativamente regionalizado para o Brasil. GPT e Gemini citaram predominantemente ReCiPe 2016 (HUIJBREGTS *et al.*, 2017); DeepSeek citou predominantemente IMPACT World+ (BULLE *et al.*, 2019). A partir de L3, todos seguiram a instrução (29 de 30 em L3 e L4 PT-BR), consistente com a recomendação de HEIJUNGS & DEKKER (2022) de explicitar o modelo e com a limitação prática de modelos globais (e.g., FANTKE *et al.*, 2019) em aplicações regionalizadas.

3.3 Concordância operacional

A Figura 2 reporta a fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto. Em L0L2 essa fração é nula ou marginal em quase todas as células. Em L3, GPT e Gemini atingem 100% em ambos os idiomas, e DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4, com fórmula explícita, os três LLMs atingem 100%.

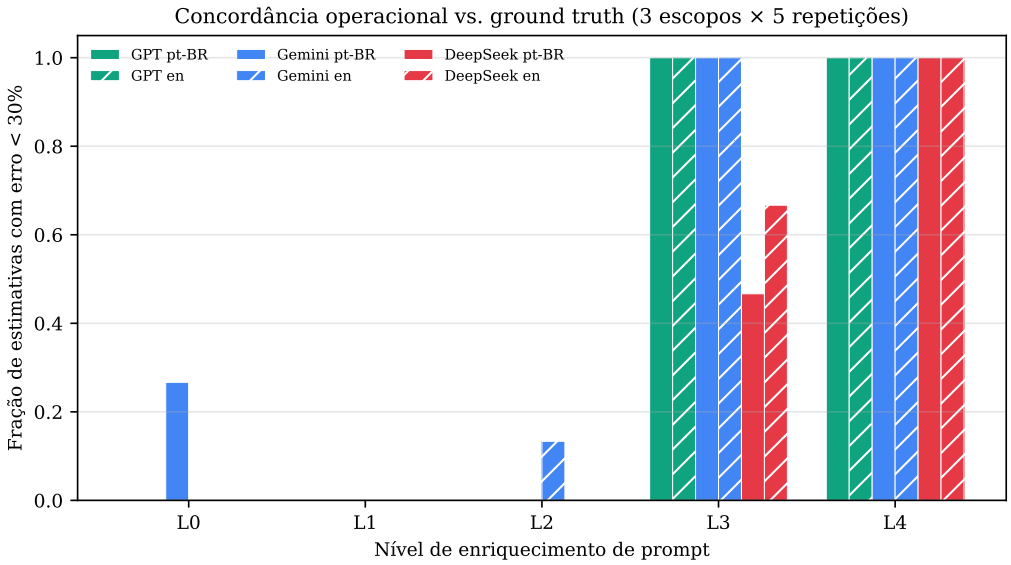


Figura 2 – Fração de estimativas com erro relativo absoluto $< 30\%$ (critério operacional de concordância).

3.4 Achados qualitativos

Recusa defensiva do GPT. O GPT retornou `null` em 100% das 10 chamadas de L2 e em 100% das 5 chamadas de L1 em EN, justificando explicitamente a ausência de fatores de caracterização como impeditivo do cálculo. Esse comportamento é replicável e consistente com a calibração de recusa documentada em GPT-4 (ACHIAM *et al.*, 2023).

Reprodutibilidade aparente do Gemini em L3 e L4. Em 60 chamadas (5 reps $\times$ 3 escopos $\times$ 2 idiomas $\times$ 2 níveis), o Gemini reproduziu o *ground truth* com erro $< 0{,}5\%$ e coeficiente de variação nulo; GPT (CV $\sim$0,080,10) e DeepSeek (CV $\sim$0,02) também se aproximaram em L4. O teste de contaminação reportado a seguir mostra que essa aparente exatidão decorre de memorização do paper-referência, não de cálculo.

Resultado do teste de contaminação. Sob inventário perturbado, os três LLMs continuam reportando o valor publicado em vez de calcular: Gemini classifica-se como *memorização* em 29 de 30 chamadas, GPT em 27 de 30 e DeepSeek em 13 de 30 (com 15 chamadas *mistas*). Apenas 2 das 90 chamadas (1 do Gemini, 1 do DeepSeek) calcularam corretamente sobre os inputs perturbados. A nota experimental explícita no prompt não alterou o padrão.

Variância em L0L2. O coeficiente de variação intra-célula em L0L2 chegou a 1,2 no Gemini, com estimativas diferindo em até uma ordem de grandeza entre repetições mesmo sob $T = 0$.

4 CONCLUSÕES

Para o caso testado (PM em sistema leiteiro confinado brasileiro, modelo Oberschelp, alocação econômica), três achados se sustentam.

Primeiro: a acurácia aparente dos LLMs nos níveis L3 e L4 decorre de **memorização do paper-referência**, não de cálculo da ACV. Sob inventário perturbado, em que o resultado correto deve mudar de forma previsível, os três LLMs continuam reportando o valor publicado: 29 de 30 chamadas do Gemini, 27 de 30 do GPT e 13 de 30 do DeepSeek classificam-se como memorização ($< 10\%$ de erro contra o GT original, mas erro substancial contra o novo GT). Esse comportamento persiste mesmo com instrução explícita no prompt para calcular estritamente com os números fornecidos.

Segundo: no uso informal típico L0 e L1, em que nenhum dado é fornecido os erros variam de 2 a 273 vezes o valor publicado, e nenhum LLM seleciona espontaneamente o modelo de caracterização regionalizado para o Brasil. As escolhas convergem para ReCiPe 2016 (GPT, Gemini) e IMPACT World+ (DeepSeek), ambos modelos de cobertura global.

Terceiro: LLMs frontier, no estado atual, não são confiáveis como calculadora de ACV regionalizada. Quando o caso está documentado na literatura, o output é o número do paper, independentemente dos dados de entrada; fora desse caso, o output é um modelo global desencaixado da regionalização desejada. A extensão para a matriz completa (4 sistemas $\times$ 5 modelos $\times$ 3 escopos) será apresentada em trabalho subsequente.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental avaliação do ciclo de vida princípios e estrutura. Rio de Janeiro: ABNT, 2009.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental avaliação do ciclo de vida requisitos e orientações. Rio de Janeiro: ABNT, 2009.

BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.

BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.

FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.

GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.

GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.

HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.

HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.

JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.

OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.

WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.