ACURÁCIA ILUSÓRIA DE LLMS EM ACV REGIONALIZADA: MEMORIZAÇÃO DO PAPER-REFERÊNCIA MASCARA INCAPACIDADE DE CÁLCULO EM DOIS SISTEMAS DE PRODUÇÃO LEITEIRA

[Identificação dos autores omitida para revisão por pares]

1 INTRODUÇÃO

Modelos de linguagem de grande porte (LLMs) foram incorporados a fluxos científicos desde a popularização do GPT-3 (BROWN *et al.*, 2020). Pesquisadores e consultores de Avaliação do Ciclo de Vida (ACV) já usam essas ferramentas para estimar fatores, revisar inventários e gerar análises a partir de descrições em linguagem natural sem protocolo, sem auditoria e sem medida de erro associada à prática.

Três lacunas convergentes motivam este trabalho. Primeiro, não há estudos que comparem estimativas de LLMs com ACVs auditadas e regionalizadas. Segundo, saídas de LLMs são fluentes mesmo quando o conteúdo é incorreto, fenômeno descrito por JI *et al.* (2023) como alucinação; em outra linha, CARLINI *et al.* (2023) demonstram que modelos memorizam conteúdo de seus dados de treinamento e o reproduzem na inferência, problema reforçado por SAINZ *et al.* (2023) ao mostrar contaminação de benchmarks científicos. Terceiro, a regionalização de impactos central para o caso brasileiro de material particulado (MP) em saúde humana (GIUSTI *et al.*, 2022, 2023) costuma ser substituída por fatores globais quando se consulta o modelo sem dados específicos. A pergunta operacional é: **em que ponto da escala de enriquecimento de prompt o LLM passa a produzir uma estimativa de ACV utilizável?**

Resultado central. A acurácia aparente dos LLMs em níveis de prompt enriquecidos não vem de cálculo, e sim de **memorização do paper-referência**. Sob inventário propositalmente perturbado, o modelo continua reportando o valor publicado em 97% das chamadas do Gemini (em dois sistemas), 90% do GPT em Sistema 1 e 43% do DeepSeek em Sistema 1, ignorando os dados de entrada. O efeito varia entre LLMs e entre sistemas, o que em si é um achado: o modelo tende a recuperar casos muito citados no corpus de treino.

2 METODOLOGIA

2.1 Paper-referência e *ground truth*

O estudo de Giusti *et al.* (2023) analisa quatro sistemas de produção leiteira brasileiros (*cradle-to-farm gate*; ABNT NBR ISO 14040 e 14044, 2009), com unidade funcional de 1 kg FPCM (*fat-and-protein corrected milk*), e aplica cinco modelos de caracterização com três níveis de regionalização. Para este resumo, fixamos dois sistemas (Sistema 1 confinado típico, com estado-alvo de São Paulo; Sistema 2 semi-intensivo, com estado-alvo do Paraná), o modelo de caracterização de OBERSCHELP *et al.* (2020) com modelo de efeito *Average* a nível do solo, e a alocação econômica. Disso resulta um *ground truth* de seis células de impacto em DALY/kg FPCM (Tabela 1). Os fatores de caracterização nativos foram extraídos do material suplementar de Oberschelp e reconciliados com a planilha de cálculo de Giusti *et al.* (2023); a discrepância máxima foi inferior a 0,1% em ambos os sistemas.

2.2 Variável independente níveis de enriquecimento de prompt

Cinco níveis ordenados foram desenhados, cada um adicionando uma dimensão de informação ao anterior: L0 (apenas a pergunta), L1 (escopo ISO 14040/14044), L2 (inventário agregado de

Tabela 1 – Ground truth Oberschelp *et al.* (2020) *Average*, alocação econômica

Escopo geográfico	Sistema 1 (SP)	Sistema 2 (PR)
Global	$2{,}830 \times 10^{-8}$	$1{,}281 \times 10^{-8}$
Brasil	$8{,}108 \times 10^{-8}$	$1{,}096 \times 10^{-7}$
Estado-alvo	$6{,}373 \times 10^{-7}$	$1{,}554 \times 10^{-7}$
Razão Estado/Global	22,5×	12,1×

Razões diferentes refletem distintos perfis de emissão por sistema e estados-alvo distintos.

28 fluxos PM-relevantes do Sistema 1, selecionados conforme o subconjunto de poluentes do modelo Oberschelp), L3 (tabela de fatores de caracterização Oberschelp para os três escopos) e L4 (procedimento explícito $I_g = \sum_i m_i \cdot CF_{i,g}$, no espírito de *chain-of-thought prompting*, WEI *et al.*, 2022).

2.3 Modelos LLM e desenho experimental

Foram avaliados três modelos LLM de fronteira: GPT (OpenAI, `gpt-4.1-2025-04-14`), Gemini 2.5 Pro (Google, `gemini-2.5-pro`) e DeepSeek V3 (`deepseek-chat`, via API). Para cada sistema, cada combinação *LLM* × *nível* × *idioma (PT-BR, EN)* foi replicada $n = 5$ vezes, com temperatura zero e *seed* 42 (OpenAI e DeepSeek; Gemini não expõe *seed* na API). O *system prompt* exigiu resposta em JSON estrito (esquema canônico), com regras explícitas contra fabricação de valores e referências. Total do experimento principal: 300 chamadas (150 por sistema), custo US$ 3,42 e tempo agregado 108 min. Somadas às 180 chamadas do teste de contaminação (descrito em ğ2.5), o estudo perfaz **480 chamadas registradas**. Prompts, respostas brutas e scripts são compartilhados em repositório público anonimizado.

2.4 Métricas e análise

Foram computadas quatro famílias de métricas: erro numérico (erro relativo absoluto, MAPE e log-razão $\log_{10}(\hat{I}/I_{GT})$); aderência metodológica (modelo de caracterização e método de alocação declarados); sensibilidade regional (presença de diferenciação entre os três escopos); e estabilidade do output (taxa de não-resposta, conformidade ao esquema JSON, coeficiente de variação intra-célula entre as repetições). O critério operacional de concordância é erro relativo absoluto $< 30\%$. Como limitação reconhecida, $n = 5$ por célula é suficiente para LLMs determinísticos sob $T = 0$ mas não permite testes inferenciais robustos; comparações usam estatística descritiva.

2.5 Controle de contaminação por treinamento

O paper-referência foi publicado em 2023, anterior ao *cutoff* de treinamento dos LLMs, o que abre a hipótese de memorização (CARLINI *et al.*, 2023). Para discriminar memorização de cálculo, replicamos L3 e L4 em PT-BR ($n = 5$) com três esquemas de inventário perturbado, em cada sistema: P1 (massas × 2); P2 (amônia × 0,1); P3 (cada substância × U[0,5; 2,0], seed fixa). O prompt traz nota experimental explícita informando que o inventário é hipotético. Cada chamada produz dois erros simultâneos: Δ_{novo} contra o novo *ground truth* calculado e Δ_{orig} contra o valor publicado. Classifica-se como *cálculo* quando $|\Delta_{\text{novo}}| < 10\%$, *memorização* quando $|\Delta_{\text{orig}}| < 10\%$, *misto* quando nenhum dos dois critérios é satisfeito e *null* quando o LLM recusa numericamente. Total: 180 chamadas adicionais (90 por sistema). Conflito de interesse: a versão final declarará vínculo entre autoria e paper-referência.

3 RESULTADOS

Das 300 chamadas do experimento principal, 297 retornaram JSON conforme o esquema (3 falhas de parsing em DeepSeek L4 EN). A taxa de resposta numérica não-`null` variou por nível e por LLM, com o GPT apresentando recusa sistemática em níveis com informação insuficiente.

3.1 Curva de saturação MAPE × nível

A Figura 1 apresenta a mediana e o intervalo interquartil do erro relativo absoluto por nível, LLM e idioma. À primeira vista, o salto principal de acurácia ocorre entre L2 e L3 e o erro cai a valores próximos de zero em L3 e L4. Essa aparente convergência é, no entanto, o sintoma central deste trabalho: como mostraremos em ğ3.4, ela é produto de memorização do paper-referência, não de cálculo.

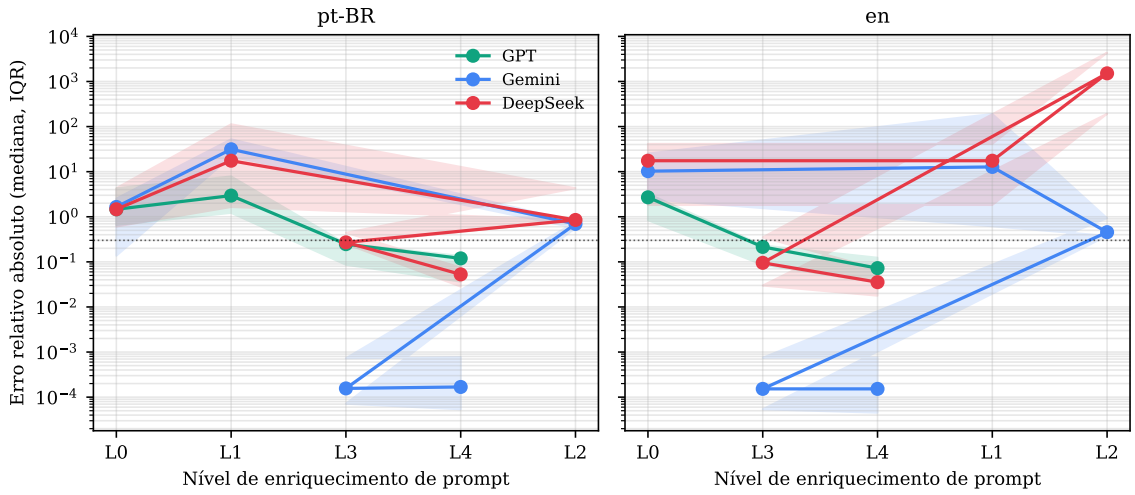


Figura 1 – Erro relativo absoluto (mediana, intervalo interquartil) por nível de enriquecimento de prompt, LLM e idioma. Eixo *y* em escala logarítmica. Linha tracejada: limiar operacional de 30%.

3.2 Comportamento metodológico (modelo declarado)

Em L0L2, nenhum LLM selecionou espontaneamente o modelo de Oberschelp *et al.* (2020), apesar de ser o modelo nativamente regionalizado para o Brasil. GPT e Gemini citaram predominantemente ReCiPe 2016 (HUIJBREGTS *et al.*, 2017); DeepSeek citou predominantemente IMPACT World+ (BULLE *et al.*, 2019). A partir de L3, todos seguiram a instrução (29 de 30 em L3 e L4 PT-BR), consistente com a recomendação de HEIJUNGS & DEKKER (2022) de explicitar o modelo e com a limitação prática de modelos globais (e.g., FANTKE *et al.*, 2019) em aplicações regionalizadas.

3.3 Concordância operacional

A Figura 2 reporta a fração de estimativas que atendem ao critério $< 30\%$ de erro relativo absoluto. Em L0L2 essa fração é nula ou marginal em quase todas as células. Em L3, GPT e Gemini atingem 100% em ambos os idiomas, e DeepSeek atinge 47% (PT-BR) e 67% (EN). Em L4, com fórmula explícita, os três LLMs atingem 100%.

3.4 Achado central: memorização vs. cálculo

Diferenciação regional. A razão Estado/Global publicada é 22,5× (S1) e 12,1× (S2). Em L0–L2, os três LLMs reportam razões entre 1,0× e 3,0×, subestimando a diferenciação em

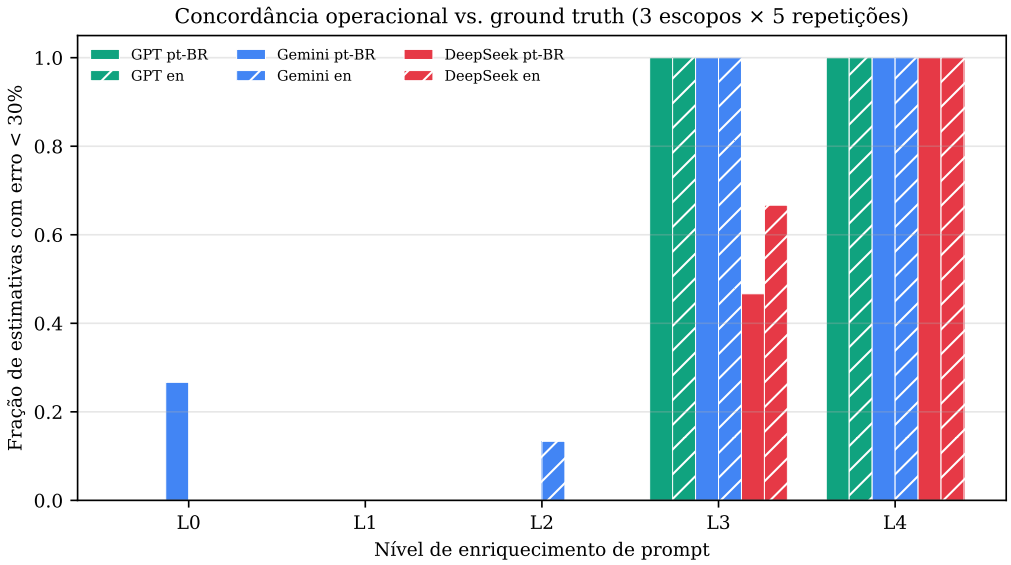


Figura 2 – Fração de estimativas com erro relativo absoluto $< 30\%$ (critério operacional de concordância).

uma a duas ordens de magnitude. Em L3–L4, Gemini reproduz a razão exata em ambos os sistemas (22,52× e 12,13×); GPT e DeepSeek aproximam-se ($\pm$10–60%). DeepSeek em L2 não diferencia regiões em 100% das chamadas.

Recusa defensiva do GPT. O GPT retornou `null` em 100% das chamadas de L2 (ambos os sistemas, ambos idiomas) e em 100% das chamadas de L1 em EN, justificando a ausência de fatores como impeditivo do cálculo (ACHIAM *et al.*, 2023).

Reprodutibilidade aparente em L3 e L4. O Gemini reproduziu o *ground truth* com erro $< 0{,}5\%$ e coeficiente de variação nulo em ambos os sistemas. O teste de contaminação (Tabela 2) mostra que essa exatidão vem da memorização do paper-referência, não de cálculo: sob inventário perturbado, Gemini classifica-se como *memorização* em 29 de 30 chamadas em cada sistema. GPT memoriza o Sistema 1 (27/30) e quase nunca o Sistema 2 (3/30, com 27 respostas *mistas*). DeepSeek mostra o menor padrão (13/30 em S1; 0/30 em S2). A nota experimental no prompt não mudou o resultado.

Tabela 2 – Teste de contaminação: classificação das chamadas L3+L4 (PT-BR, $n = 30$ por LLM por sistema).

	Sistema 1 (SP)				Sistema 2 (PR)			
LLM	Calc.	Mem.	Misto	Null	Calc.	Mem.	Misto	Null
GPT	0	27	3	0	0	3	27	0
Gemini	1	29	0	0	1	29	0	0
DeepSeek	1	13	15	1	4	0	21	5

Variância em L0L2. O coeficiente de variação intra-célula em L0L2 chegou a 1,2 no Gemini, com estimativas diferindo em até uma ordem de grandeza entre repetições mesmo sob $T = 0$.

4 CONCLUSÕES

Para os dois sistemas testados (confinado/SP e semi-intensivo/PR, modelo Oberschelp, alocação econômica), a acurácia aparente dos LLMs em L3 e L4 vem da memorização do paper-

referência, não de cálculo. O gradiente Gemini → GPT → DeepSeek e a diferença GPT entre Sistema 1 e Sistema 2 sugerem que o paper-alvo chegou aos corpora de treinamento em doses distintas e que o modelo recupera com mais facilidade casos muito citados.

No uso informal típico L0 e L1, sem dados fornecidos os erros variam de uma faixa de 2 a 273 vezes o valor publicado; nenhum LLM seleciona espontaneamente o modelo regionalizado para o Brasil, convergindo para ReCiPe 2016 (GPT, Gemini) e IMPACT World+ (DeepSeek). A magnitude da diferenciação regional é subestimada em uma a duas ordens de grandeza.

A matriz completa do paper-referência (4 sistemas × 5 modelos × 3 escopos) será apresentada em trabalho subsequente. **O ponto operacional, contudo, já se sustenta: se o caso já está na literatura, o LLM devolve o número publicado e ignora o inventário; se não está, devolve um fator global qualquer.** Nenhum dos dois comportamentos é cálculo de ACV.

REFERÊNCIAS

ACHIAM, J. *et al.* GPT-4 technical report. **arXiv preprint**, arXiv:2303.08774, 2023.

CARLINI, N. *et al.* Quantifying memorization across neural language models. In: **International Conference on Learning Representations** (ICLR), 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14040**: gestão ambiental avaliação do ciclo de vida princípios e estrutura. Rio de Janeiro: ABNT, 2009.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 14044**: gestão ambiental avaliação do ciclo de vida requisitos e orientações. Rio de Janeiro: ABNT, 2009.

BROWN, T. *et al.* Language models are few-shot learners. **Advances in Neural Information Processing Systems**, v. 33, p. 1877–1901, 2020.

BULLE, C. *et al.* IMPACT World+: a globally regionalized life cycle impact assessment method. **The International Journal of Life Cycle Assessment**, v. 24, p. 1653–1674, 2019.

FANTKE, P. *et al.* Global effect factors for exposure to fine particulate matter. **Environmental Science & Technology**, v. 53, n. 12, p. 6855–6868, 2019.

GIUSTI, G. *et al.* Health effects of particulate matter formation in life cycle impact assessment: critical review and recommendation of models for Brazil. **The International Journal of Life Cycle Assessment**, v. 27, p. 868–884, 2022.

GIUSTI, G. *et al.* Human health impacts of particulate matter emitted from different milk production systems in Brazil: a regionalized LCA sensitivity analysis. **The International Journal of Life Cycle Assessment**, 2023. DOI: 10.1007/s11367-023-02184-8.

HEIJUNGS, R.; DEKKER, E. Meta-comparisons: how to compare methods for LCA? **The International Journal of Life Cycle Assessment**, v. 27, p. 993–1015, 2022.

HUIJBREGTS, M. A. J. *et al.* ReCiPe2016: a harmonised life cycle impact assessment method at midpoint and endpoint level. **The International Journal of Life Cycle Assessment**, v. 22, p. 138–147, 2017.

JI, Z. *et al.* Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023.

OBERSCHELP, C. *et al.* Globally regionalized monthly life cycle impact assessment of particulate matter. **Environmental Science & Technology**, 2020. DOI: 10.1021/acs.est.0c05691.

SAINZ, O. *et al.* NLP evaluation in trouble: on the need to measure LLM data contamination for each benchmark. In: **Findings of EMNLP**, 2023.

WEI, J. *et al.* Chain-of-thought prompting elicits reasoning in large language models. **Advances in Neural Information Processing Systems**, v. 35, 2022.