MATERIAL COMPLEMENTAR

TESTE DE CONTAMINAÇÃO EM LLMS APLICADOS À ACV REGIONALIZADA DO MATERIAL PARTICULADO EM PRODUÇÃO LEITEIRA

Lucas Rover — PPGSAU/UTFPR — lucasrover@alunos.utfpr.edu.br
Yara de Souza Tadano — PPGSAU/UTFPR — yaratadano@utfpr.edu.br

Este material complementar acompanha o resumo expandido submetido ao 9ž Congresso Brasileiro sobre Gestão do Ciclo de Vida (GCV 2026) e reúne, em formato auditável: (i) os prompts utilizados em português e inglês; (ii) o inventário pré-processado e os fatores de caracterização que alimentaram os prompts; (iii) tabelas detalhadas dos 480 outputs registrados; (iv) figuras adicionais; (v) parâmetros completos do desenho experimental e de reprodutibilidade. Todo o pipeline, dados brutos e código de análise estão em repositório público (`https://github.com/Roverlucas/ia-acv-gcv2026`).

Contents

1 Detalhamento metodológico **2**
1.1 Versões dos modelos e parâmetros de chamada . . . 2
1.2 Esquema canônico da resposta JSON . . . 2
1.3 Critérios operacionais (recapitulação) . . . 3

2 Prompts utilizados (PT-BR e EN) **3**
2.1 Instrução de sistema (PT-BR) . . . 3
2.2 Instrução de sistema (EN) . . . 4
2.3 Nível L0 — Zero context . . . 5
2.3.1 Português . . . 5
2.3.2 Inglês . . . 5
2.4 Nível L1 — Scoped . . . 6
2.4.1 Português . . . 6
2.4.2 Inglês . . . 6
2.5 Nível L2 — com LCI . . . 7
2.5.1 Português . . . 7
2.5.2 Inglês . . . 7
2.6 Nível L3 — com fatores . . . 8
2.6.1 Português . . . 8
2.6.2 Inglês . . . 8
2.7 Nível L4 — com procedimento . . . 9
2.7.1 Português . . . 9
2.7.2 Inglês . . . 10

3 Dados pré-processados injetados nos prompts **11**
3.1 Sistema 1 — inventário PM-relevante (alocação econômica) . . . 11
3.2 Sistema 2 — inventário PM-relevante (alocação econômica) . . . 12
3.3 Sistema 1 — fatores de caracterização Oberschelp (2020) . . . 12
3.4 Sistema 2 — fatores de caracterização Oberschelp (2020) . . . 13

4 Resultados completos do experimento principal **13**
4.1 MAPE por (LLM × nível × idioma × escopo) 13
4.2 Curvas de saturação por sistema 14
4.3 Distribuição da log-razão 14
4.4 Coeficiente de variação intra-célula 14
4.5 Modelo de caracterização declarado pelos LLMs 14

5 Teste de contaminação — detalhado **14**
5.1 Esquemas de perturbação 14
5.2 Classificação por (sistema × LLM × esquema × nível) 15
5.3 Resposta do LLM vs. novo *ground truth* 15

6 Comparação com o paper-referência **15**
6.1 Tabela comparativa Giusti vs. LLMs 15
6.2 Análise de sensibilidade ao limiar de classificação 16
6.3 Decomposição da memorização por perturbação e por nível 16

7 Diferenciação regional **17**

8 Reprodutibilidade **17**
8.1 Repositório público 17
8.2 Estrutura do repositório 17
8.3 Conformidade de *schema* JSON 19
8.4 Custo agregado 19
8.5 Conflito de interesse 19

1 DETALHAMENTO METODOLÓGICO

1.1 VERSÕES DOS MODELOS E PARÂMETROS DE CHAMADA

A Tabela 1 apresenta as versões exatas dos LLMs e os parâmetros de chamada utilizados em todas as 480 inferências registradas.

Table 1 – Modelos LLM avaliados e parâmetros de chamada

Provedor	**Modelo**	**Versão da API**	***Seed* suportado**
OpenAI	GPT-4.1	`gpt-4.1-2025-04-14`	42
Google	Gemini 2.5 Pro	`gemini-2.5-pro`	Não suportado
DeepSeek	DeepSeek V3	`deepseek-chat`	42

Fonte: autores. Temperatura fixada em 0 em todas as chamadas. *Max output tokens*: 4096 (OpenAI, DeepSeek); 16 384 (Gemini, devido ao uso interno de *thinking tokens*). Formato de resposta forçado a JSON (*response_format*) em OpenAI e DeepSeek.

1.2 ESQUEMA CANÔNICO DA RESPOSTA JSON

Todas as respostas exigidas em formato JSON estrito, validadas contra o esquema:

```
{
  "answer": {
    "global":   { "value": <numero ou null>, "unit": "DALY/kg FPCM" },
    "brazil":   { "value": <numero ou null>, "unit": "DALY/kg FPCM" },
    "state":    { "value": <numero ou null>, "unit": "DALY/kg FPCM" }
```

```
  },
  "characterization_model": "<modelo adotado>",
  "allocation_method": "<economic | mass | system_expansion | none | other |
    unspecified>",
  "reasoning": "<raciocinio passo a passo>",
  "intermediate_steps": [ { "step": "...", "value": <num>, "unit": "..." } ],
  "references": [ { "citation": "...", "doi": "..." } ],
  "uncertainties": "<o que nao foi possivel calcular>",
  "confidence": "<low | medium | high>"
}
```

1.3 CRITÉRIOS OPERACIONAIS (RECAPITULAÇÃO)

Concordância operacional. Erro relativo absoluto $< 30\%$ contra o *ground truth* publicado.

Classificação do teste de contaminação (Seção 5):

- *Cálculo*: $|\Delta_{\text{novo}}| < 10\%$ contra o novo GT calculado a partir do inventário perturbado.
- *Memorização*: $|\Delta_{\text{orig}}| < 10\%$ contra o GT publicado em Giusti *et al.* (2023).
- *Misto*: nenhum dos dois critérios é satisfeito.
- *Null*: o LLM recusa numericamente (retorna `null`).

2 PROMPTS UTILIZADOS (PT-BR E EN)

Esta seção reproduz o texto integral dos prompts utilizados em todas as 480 chamadas. Os *placeholders* `{{LCI_TABLE}}`, `{{CF_TABLE_OBERSCHELP}}`, `{{STATE_NAME_PT}}`, `{{STATE_NAME_EN}}` e `{{STATE_CODE}}` são substituídos automaticamente pelo orquestrador (`src/render_prompt.py`) com os valores apropriados para cada sistema avaliado (S1: São Paulo/SP; S2: Paraná/PR).

2.1 INSTRUÇÃO DE SISTEMA (PT-BR)

```
Você é um assistente técnico-científico especializado em Avaliação do Ciclo de Vida
    (ACV / LCA), familiarizado com a metodologia ISO 14040/14044 e com modelos de
    caracterização para a categoria de impacto **impacto do material particulado na
    saúde humana**, expressa em DALY.

Sua tarefa é responder à pergunta do usuário fornecendo uma **estimativa numérica
    concreta** quando possível, e indicando explicitamente quando não for possível.

**Regras de resposta  leia com atenção:**

1. **Formato de saída**: responda EXCLUSIVAMENTE com um objeto JSON válido (RFC 8259),
    conforme o esquema fornecido ao final desta instrução. Sem markdown fences (sem
    ```json), sem texto antes nem depois. Apenas o JSON.
   - **Valores numéricos devem ser literais** (ex.: `1.5e-07`), **NUNCA expressões
    aritméticas** (ex.: `1.1e-04 + 9e-06` é JSON inválido). Faça a soma você mesmo e
    escreva o resultado final.
   - Aspas duplas para strings; chaves entre aspas. Sem trailing commas.

2. **Honestidade epistêmica**: se você não tem informação suficiente para uma
    estimativa numérica, retorne `value: null` no campo correspondente  *não fabrique
    valores*. Documente o motivo no campo `uncertainties`.

3. **Sem alucinação de referências**: somente cite trabalhos que você sabe que existem.
    Prefira indicar o DOI quando souber. Se não tem certeza sobre uma referência,
    OMITA-A. Referências fabricadas serão tratadas como falha grave do output.

4. **Regionalização**: se você cita um modelo de caracterização, indique explicitamente
    em que nível de regionalização (global, nacional, estadual, urbano/rural) os
    fatores são aplicáveis.
```
```

```
5. **Unidades**: todas as estimativas de impacto devem estar em **DALY/kg FPCM**
     (Disability-Adjusted Life Year por kg de leite corrigido por gordura e proteína),
     referentes à categoria **impacto do material particulado na saúde humana**. Faça as
     conversões necessárias.

6. **Coerência interna**: se você apresenta números intermediários (massa, fatores de
     caracterização, somas), eles devem aritmeticamente conduzir ao número final. Mostre
     os passos no campo `reasoning` ou `intermediate_steps`.

7. **Alocação**: declare explicitamente o método de alocação adotado para os coprodutos
     (leite, carne, biofertilizante)  econômica, mássica, expansão de sistema, ou nenhum.

8. **Sem disclaimers genéricos**: não inclua textos como "consulte sempre um
     especialista" ou "este resultado é apenas estimativo"  isso já está implícito. Use
     o campo `uncertainties` para esse tipo de afirmação.

**Esquema JSON obrigatório** (campos obrigatórios em negrito):

```
{
  "answer": {
    "global":   { "value": <número ou null>, "unit": "DALY/kg FPCM" },
    "brazil":   { "value": <número ou null>, "unit": "DALY/kg FPCM" },
    "state":   { "value": <número ou null>, "unit": "DALY/kg FPCM" }
  },
  "characterization_model": "<modelo adotado>",
  "allocation_method": "<economic | mass | system_expansion | none | other |
    unspecified>",
  "reasoning": "<raciocínio passo a passo em texto contínuo>",
  "intermediate_steps": [
    { "step": "<descrição>", "value": <número>, "unit": "<unidade>" }
  ],
  "references": [
    { "citation": "<referência completa>", "doi": "<DOI se souber>" }
  ],
  "uncertainties": "<o que não foi possível calcular ou onde a estimativa é fraca>",
  "confidence": "<low | medium | high>"
}
```
```

2.2 INSTRUÇÃO DE SISTEMA (EN)

```
You are a technical-scientific assistant specialized in Life Cycle Assessment (LCA),
     familiar with ISO 14040/14044 methodology and characterization models for the
     **human health impact of particulate matter** impact category, expressed in DALY.

Your task is to answer the user's question providing a **concrete numerical estimate**
     when possible, and explicitly indicating when it is not.

**Response rules  read carefully:**

1. **Output format**: respond EXCLUSIVELY with a valid JSON object (RFC 8259),
     following the schema provided at the end of these instructions. No markdown fences
     (no ```json), no text before or after. Only the JSON.
   - **Numeric values must be literals** (e.g. `1.5e-07`), **NEVER arithmetic
     expressions** (e.g. `1.1e-04 + 9e-06` is invalid JSON). Compute the sum yourself
     and write the final result.
   - Double quotes for strings; quoted keys. No trailing commas.

2. **Epistemic honesty**: if you don't have enough information for a numerical
     estimate, return `value: null` in the corresponding field  *do not fabricate
     values*. Document the reason in the `uncertainties` field.

3. **No reference hallucination**: only cite works you know to exist. Prefer indicating
     the DOI when known. If you are not certain about a reference, OMIT IT. Fabricated
     references will be treated as a critical output failure.

4. **Regionalization**: when citing a characterization model, explicitly indicate the
     level of regionalization (global, national, state-level, urban/rural) at which the
     factors are applicable.
```

```
5. **Units**: all impact estimates must be in **DALY/kg FPCM** (Disability-Adjusted
    Life Year per kg of fat-and-protein-corrected milk), referring to the **human
    health impact of particulate matter** category. Make the necessary conversions.

6. **Internal coherence**: if you present intermediate numbers (mass, characterization
    factors, sums), they must arithmetically lead to the final number. Show the steps
    in `reasoning` or `intermediate_steps`.

7. **Allocation**: explicitly state the allocation method adopted for the co-products
    (milk, meat, biofertilizer)  economic, mass-based, system expansion, or none.

8. **No generic disclaimers**: do not include text such as "always consult a
    specialist" or "this result is only an estimate"  that is already implicit. Use the
    `uncertainties` field for that kind of statement.

**Mandatory JSON schema** (required fields in bold):

```
{
  "answer": {
    "global":   { "value": <number or null>, "unit": "DALY/kg FPCM" },
    "brazil":   { "value": <number or null>, "unit": "DALY/kg FPCM" },
    "state":   { "value": <number or null>, "unit": "DALY/kg FPCM" }
  },
  "characterization_model": "<adopted model>",
  "allocation_method": "<economic | mass | system_expansion | none | other |
    unspecified>",
  "reasoning": "<step-by-step reasoning as continuous text>",
  "intermediate_steps": [
    { "step": "<description>", "value": <number>, "unit": "<unit>" }
  ],
  "references": [
    { "citation": "<full reference>", "doi": "<DOI if known>" }
  ],
  "uncertainties": "<what could not be calculated or where the estimate is weak>",
  "confidence": "<low | medium | high>"
}
```
```

2.3 NÍVEL L0 — ZERO CONTEXT

2.3.1 Português

```
# L0  Zero context (PT-BR)

> Nível L0 da escala de enriquecimento de prompt. **Nenhum** contexto técnico,
    metodológico ou de dados é fornecido. A IA deve responder usando apenas o que sabe.

---

## Pergunta

Em um estudo de ACV de produção de leite no Brasil, qual é o **impacto do material
    particulado na saúde humana**, em DALY/kg FPCM? Forneça uma estimativa para escopo
    **Global**, **Brasil** e **{{STATE_NAME_PT}}**.

Responda no formato JSON especificado.
```

2.3.2 Inglês

```
# L0  Zero context (EN)

> Level L0 of the prompt-enrichment scale. **No** technical, methodological or data
    context is provided. The AI must respond using only what it knows.

---

## Question
```

```
In an LCA study of milk production in Brazil, what is the **human health impact of
    particulate matter**, in DALY/kg FPCM? Provide an estimate for **Global**,
    **Brazil** and **{{STATE_NAME_EN}}** scopes.

Respond in the specified JSON format.
```

2.4 NÍVEL L1 — SCOPED

2.4.1 Português

```
# L1  Scoped question (PT-BR)

> Nível L1: pergunta delimitada com escopo ISO 14040/14044. **Não** são fornecidos
    dados de inventário, fatores de caracterização nem procedimento de cálculo.

---

## Escopo do estudo de ACV

- **Unidade funcional**: 1 kg de leite corrigido por gordura e proteína (FPCM
    *fat-and-protein corrected milk*)
- **Fronteira do sistema**: *cradle-to-farm gate* (do berço ao portão da fazenda)
- **Categoria de impacto**: **impacto do material particulado na saúde humana**
- **Indicador**: DALY (Disability-Adjusted Life Years)
- **Coprodutos do sistema**: leite, carne (descarte), biofertilizante (esterco)
- **Região de origem**: sistemas leiteiros brasileiros típicos
- **Escopos geográficos de avaliação do impacto**: Global, Brasil, {{STATE_NAME_PT}}

## Pergunta

Considerando o escopo do estudo de ACV definido acima, qual é o **impacto do material
    particulado na saúde humana**, em DALY/kg FPCM, decorrente da produção de leite no
    Brasil, para cada um dos três escopos geográficos (Global, Brasil,
    {{STATE_NAME_PT}})?

Responda no formato JSON especificado.
```

2.4.2 Inglês

```
# L1  Scoped question (EN)

> Level L1: question scoped using ISO 14040/14044. **No** inventory data,
    characterization factors or calculation procedure are provided.

---

## LCA study scope

- **Functional unit**: 1 kg of fat-and-protein-corrected milk (FPCM)
- **System boundary**: cradle-to-farm gate
- **Impact category**: **human health impact of particulate matter**
- **Indicator**: DALY (Disability-Adjusted Life Years)
- **Co-products of the system**: milk, meat (cull), biofertilizer (manure)
- **Region of origin**: typical Brazilian dairy systems
- **Geographic scopes of impact assessment**: Global, Brazil, {{STATE_NAME_EN}}

## Question

Given the scope defined above, what is the **human health impact of particulate
    matter**, in DALY/kg FPCM, from milk production in Brazil, for each of the three
    geographic scopes (Global, Brazil, {{STATE_NAME_EN}})?

Respond in the specified JSON format.
```

2.5 NÍVEL L2 — COM LCI

2.5.1 Português

```
# L2  Scoped + LCI agregado (PT-BR)

> Nível L2: L1 + inventário do ciclo de vida (LCI) agregado de emissões para o ar
    relevantes a material particulado, do sistema-alvo. **Não** são fornecidos fatores
    de caracterização nem procedimento de cálculo.

---

## Escopo do estudo de ACV

- **Unidade funcional**: 1 kg FPCM
- **Fronteira do sistema**: *cradle-to-farm gate*
- **Categoria de impacto**: **impacto do material particulado na saúde humana**
- **Indicador**: DALY/kg FPCM
- **Coprodutos**: leite, carne (descarte), biofertilizante
- **Alocação aplicada ao inventário abaixo**: **econômica**
- **Sistema**: produção leiteira brasileira (sistema confinado típico)

## Inventário do ciclo de vida (emissões para ar, alocação econômica)

A tabela abaixo apresenta o LCI agregado de emissões para ar do sistema, com massa
    total (kg) por substância e por compartimento de emissão, por kg de FPCM (alocação
    econômica já aplicada). Valores derivados de inventário composto com upstream
    ecoinvent.

{{LCI_TABLE}}

## Pergunta

Considerando o escopo do estudo de ACV e o inventário acima, qual é o **impacto do
    material particulado na saúde humana**, em DALY/kg FPCM, para cada um dos três
    escopos geográficos: **Global**, **Brasil** e **{{STATE_NAME_PT}}**?

Responda no formato JSON especificado.
```

2.5.2 Inglês

```
# L2  Scoped + aggregated LCI (EN)

> Level L2: L1 + aggregated life cycle inventory (LCI) of air emissions relevant to
    particulate matter for the target system. **No** characterization factors or
    calculation procedure are provided.

---

## LCA study scope

- **Functional unit**: 1 kg FPCM
- **System boundary**: cradle-to-farm gate
- **Impact category**: **human health impact of particulate matter**
- **Indicator**: DALY/kg FPCM
- **Co-products**: milk, meat (cull), biofertilizer
- **Allocation applied to the inventory below**: **economic**
- **System**: typical Brazilian confined dairy system

## Life cycle inventory (air emissions, economic allocation)

The table below presents the aggregated LCI of air emissions for the system, with total
    mass (kg) per substance and emission compartment, per kg FPCM (economic allocation
    already applied). Values derived from a composite inventory with ecoinvent upstream.

{{LCI_TABLE}}

## Question

Given the LCA study scope and the inventory above, what is the **human health impact of
    particulate matter**, in DALY/kg FPCM, for each of the three geographic scopes:
    **Global**, **Brazil**, and **{{STATE_NAME_EN}}**?
```

```
Respond in the specified JSON format.
```

2.6 NÍVEL L3 — COM FATORES

2.6.1 Português

```
# L3  Scoped + LCI + fatores de caracterização (PT-BR)

> Nível L3: L2 + tabela de fatores de caracterização (Oberschelp et al., 2020) para as
    substâncias e escopos geográficos relevantes. **Não** é fornecido o procedimento
    explícito de cálculo.

---

## Escopo do estudo de ACV

- **Unidade funcional**: 1 kg FPCM
- **Fronteira do sistema**: *cradle-to-farm gate*
- **Categoria de impacto**: **impacto do material particulado na saúde humana**
- **Indicador**: DALY/kg FPCM
- **Coprodutos**: leite, carne (descarte), biofertilizante
- **Alocação aplicada ao inventário**: **econômica**
- **Modelo de caracterização a ser adotado**: **Oberschelp et al. (2020)**  *Globally
    regionalized monthly life cycle impact assessment of particulate matter*.
    Environmental Science & Technology. DOI: 10.1021/acs.est.0c05691

## Inventário do ciclo de vida (emissões para ar, alocação econômica)

{{LCI_TABLE}}

## Fatores de caracterização  Oberschelp et al. (2020)

Os fatores abaixo são fatores nativos do modelo Oberschelp et al. (2020), em DALY/kg de
    substância emitida, para as três escalas geográficas pertinentes ao sistema
    brasileiro (modelo de efeito *Average*, ground-level, anual, dia-noite):

{{CF_TABLE_OBERSCHELP}}

## Pergunta

Considerando o escopo do estudo de ACV, o inventário e os fatores de caracterização
    fornecidos, qual é o **impacto do material particulado na saúde humana**, em
    DALY/kg FPCM, para cada um dos três escopos geográficos: **Global**, **Brasil** e
    **{{STATE_NAME_PT}}**?

Responda no formato JSON especificado.
```

2.6.2 Inglês

```
# L3  Scoped + LCI + characterization factors (EN)

> Level L3: L2 + characterization factor table (Oberschelp et al., 2020) for the
    relevant substances and geographic scopes. **No** explicit calculation procedure is
    provided.

---

## LCA study scope

- **Functional unit**: 1 kg FPCM
- **System boundary**: cradle-to-farm gate
- **Impact category**: **human health impact of particulate matter**
- **Indicator**: DALY/kg FPCM
- **Co-products**: milk, meat (cull), biofertilizer
- **Allocation applied to the inventory**: **economic**
- **Characterization model to be adopted**: **Oberschelp et al. (2020)**  *Globally
    regionalized monthly life cycle impact assessment of particulate matter*.
    Environmental Science & Technology. DOI: 10.1021/acs.est.0c05691
```

```
## Life cycle inventory (air emissions, economic allocation)

{{LCI_TABLE}}

## Characterization factors  Oberschelp et al. (2020)

The factors below are native factors from Oberschelp et al. (2020), in DALY/kg of
    emitted substance, for the three geographic scales relevant to the Brazilian system
    (effect model *Average*, ground level, annual, day-night):

{{CF_TABLE_OBERSCHELP}}

## Question

Given the LCA study scope, the inventory and the characterization factors provided,
    what is the **human health impact of particulate matter**, in DALY/kg FPCM, for
    each of the three geographic scopes: **Global**, **Brazil**, and
    **{{STATE_NAME_EN}}**?

Respond in the specified JSON format.
```

2.7 NÍVEL L4 — COM PROCEDIMENTO

2.7.1 Português

```
# L4  Scoped + LCI + fatores + procedimento explícito (PT-BR)

> Nível L4: L3 + procedimento de cálculo, regras de regionalização e fórmula explícita.
    **Máximo contexto**. Se a IA falhar neste nível, a falha não pode ser atribuída a
    falta de informação.

---

## Escopo do estudo de ACV

- **Unidade funcional**: 1 kg FPCM
- **Fronteira do sistema**: *cradle-to-farm gate*
- **Categoria de impacto**: **impacto do material particulado na saúde humana**
- **Indicador**: DALY/kg FPCM
- **Coprodutos**: leite, carne (descarte), biofertilizante
- **Alocação aplicada ao inventário**: **econômica** (já aplicada nas massas abaixo)
- **Modelo de caracterização**: **Oberschelp et al. (2020)** (modelo de efeito
    *Average*, ground-level)

## Inventário do ciclo de vida (emissões para ar, alocação econômica)

{{LCI_TABLE}}

## Fatores de caracterização  Oberschelp et al. (2020)

{{CF_TABLE_OBERSCHELP}}

## Procedimento de cálculo

Aplique o procedimento descrito abaixo, sem desviar.

### Passo 1  Soma ponderada por escopo geográfico

Para cada escopo geográfico **g  {Global, Brasil, Estado-{{STATE_CODE}}}**, calcule o
    impacto total em saúde humana **I_g** pela seguinte fórmula:

```
I_g = _i  ( m_i × CF_{i,g} )
```

onde:

- *i* indexa cada substância da tabela de inventário (Ammonia, Nitrogen oxides, Sulfur
    dioxide, Particulates < 2.5 m)
- *m_i* é a massa total emitida da substância *i* (kg/kg FPCM), conforme inventário
```

```
- *CF_{i,g}* é o fator de caracterização Oberschelp da substância *i* no escopo
    geográfico *g* (DALY/kg de substância), conforme tabela de fatores

### Passo 2  Unidade final

Reporte **I_g** em **DALY/kg FPCM** para cada um dos três escopos. Este valor
    representa o **impacto do material particulado na saúde humana**.

### Passo 3  Regionalização

Não aplique fatores de escala adicionais entre os escopos: cada CF já está calibrado
    para sua escala geográfica. A diferença entre I_Global, I_Brasil e
    I_Estado-{{STATE_CODE}} deve emergir naturalmente das diferenças entre os CFs.

### Passo 4  Alocação

A alocação econômica já foi aplicada ao inventário fornecido. Não reaplique alocação.

### Passo 5  Coerência

Verifique antes de retornar:
- Unidades dimensionalmente consistentes (DALY/kg FPCM)
- Cada CF foi multiplicado pela massa correspondente da MESMA substância
- A soma dos produtos resulta em um número positivo da ordem esperada (10 a 10 DALY/kg
    FPCM)

## Pergunta

Aplique o procedimento acima ao inventário e aos fatores fornecidos. Reporte
    **I_Global**, **I_Brasil** e **I_Estado-{{STATE_CODE}}** em DALY/kg FPCM (impacto
    do material particulado na saúde humana).

Responda no formato JSON especificado, incluindo todos os passos intermediários em
    `intermediate_steps`.
```

2.7.2 Inglês

```
# L4  Scoped + LCI + factors + explicit procedure (EN)

> Level L4: L3 + calculation procedure, regionalization rules and explicit formula.
    **Maximum context**. If the AI fails at this level, the failure cannot be
    attributed to lack of information.

---

## LCA study scope

- **Functional unit**: 1 kg FPCM
- **System boundary**: cradle-to-farm gate
- **Impact category**: **human health impact of particulate matter**
- **Indicator**: DALY/kg FPCM
- **Co-products**: milk, meat (cull), biofertilizer
- **Allocation applied to the inventory**: **economic** (already applied to the masses
    below)
- **Characterization model**: **Oberschelp et al. (2020)** (effect model *Average*,
    ground-level)

## Life cycle inventory (air emissions, economic allocation)

{{LCI_TABLE}}

## Characterization factors  Oberschelp et al. (2020)

{{CF_TABLE_OBERSCHELP}}

## Calculation procedure

Apply the procedure described below, without deviating.

### Step 1  Weighted sum per geographic scope
```

```
For each geographic scope **g  {Global, Brazil, State-{{STATE_CODE}}}**, compute the
    total human health impact **I_g** using the following formula:

```
I_g = _i ( m_i × CF_{i,g} )
```

where:

- *i* indexes each substance in the inventory table (Ammonia, Nitrogen oxides, Sulfur
    dioxide, Particulates < 2.5 m)
- *m_i* is the total emitted mass of substance *i* (kg/kg FPCM), as per the inventory
- *CF_{i,g}* is the Oberschelp characterization factor of substance *i* at geographic
    scope *g* (DALY/kg of substance), as per the CF table

Step 2 Final unit

Report **I_g** in **DALY/kg FPCM** for each of the three scopes. This value represents
    the **human health impact of particulate matter**.

Step 3 Regionalization

Do not apply additional scale factors between scopes: each CF is already calibrated to
    its geographic scale. The differences between I_Global, I_Brazil and
    I_State-{{STATE_CODE}} should emerge naturally from the differences between CFs.

Step 4 Allocation

Economic allocation has already been applied to the inventory provided. Do not re-apply
    allocation.

Step 5 Coherence

Before returning, verify:
- Units dimensionally consistent (DALY/kg FPCM)
- Each CF multiplied by the mass of the SAME substance
- Sum of products yields a positive number of expected order of magnitude (10 to 10
    DALY/kg FPCM)

Question

Apply the procedure above to the inventory and factors provided. Report **I_Global**,
    I_Brazil and **I_State-{{STATE_CODE}}** in DALY/kg FPCM (human health impact of
    particulate matter).

Respond in the specified JSON format, including all intermediate steps in
    `intermediate_steps`.
```

3 DADOS PRÉ-PROCESSADOS INJETADOS NOS PROMPTS

Esta seção reproduz os blocos de dados (inventários agregados e fatores de caracterização) substituídos nos *placeholders* dos prompts L2–L4 para cada sistema. A reconciliação dos fatores nativos extraídos do material suplementar de Oberschelp *et al.* (2020) com a planilha de cálculo de Giusti *et al.* (2023) apresentou discrepância inferior a 0,1%.

3.1 SISTEMA 1 — INVENTÁRIO PM-RELEVANTE (ALOCAÇÃO ECONÔMICA)

Substância	Compartimento	Quantidade (kg / kg FPCM)
Ammonia	low population density	9.6973e-04
Nitrogen oxides	low population density	4.0508e-04
Sulfur dioxide	low population density	1.2748e-04
Particulates, < 2.5 um	low population density	1.1275e-04
Nitrogen oxides	unspecified	8.0895e-05
Particulates, > 2.5 um, and < 10um	low population density	7.2261e-05
Sulfur dioxide	high population density	6.9403e-05
Particulates, > 10 um	low population density	6.5015e-05

Nitrogen oxides	high population density	4.5421e-05
Sulfur dioxide	unspecified	2.6520e-05
Particulates, > 10 um	unspecified	1.5949e-05
Ammonia	high population density	1.1097e-05
Particulates, > 2.5 um, and < 10um	high population density	9.3804e-06
Particulates, < 2.5 um	high population density	9.0156e-06
Particulates, < 2.5 um	unspecified	4.9887e-06
Particulates, > 2.5 um, and < 10um	unspecified	4.2138e-06
Particulates, > 10 um	high population density	3.5852e-06
Ammonia	unspecified	2.7882e-06
Particulates, > 10 um	low population density (long-term)	2.7748e-06
Particulates, > 2.5 um, and < 10um	low population density (long-term)	1.9538e-06
Particulates, < 2.5 um	low population density (long-term)	1.1121e-06
Sulfur dioxide	low population density (long-term)	1.4373e-07
Nitrogen oxides	low population density (long-term)	1.2166e-07
Ammonia	low population density (long-term)	6.3068e-08
Nitrogen oxides	lower stratosphere + upper troposphere	5.7297e-09
Ammonia	industrial	5.3392e-11
Sulfur dioxide	lower stratosphere + upper troposphere	4.3668e-11
Particulates, < 2.5 um	lower stratosphere + upper troposphere	8.7664e-12

3.2 SISTEMA 2 — INVENTÁRIO PM-RELEVANTE (ALOCAÇÃO ECONÔMICA)

Substância	Compartimento	Quantidade (kg / kg FPCM)
Ammonia	low population density	3.0111e-04
Nitrogen oxides	low population density	2.0721e-04
Sulfur dioxide	low population density	1.0258e-04
Particulates, < 2.5 um	low population density	9.1741e-05
Sulfur dioxide	high population density	8.8345e-05
Particulates, > 2.5 um, and < 10um	low population density	5.9490e-05
Nitrogen oxides	high population density	5.4653e-05
Particulates, > 10 um	low population density	4.7238e-05
Nitrogen oxides	unspecified	4.1960e-05
Sulfur dioxide	unspecified	1.3527e-05
Particulates, > 10 um	unspecified	9.7557e-06
Particulates, < 2.5 um	high population density	8.1504e-06
Particulates, > 2.5 um, and < 10um	high population density	3.9159e-06
Ammonia	high population density	2.8134e-06
Particulates, < 2.5 um	unspecified	2.7487e-06
Particulates, > 10 um	high population density	2.6992e-06
Particulates, > 2.5 um, and < 10um	unspecified	2.2041e-06
Ammonia	unspecified	1.2391e-06
Particulates, > 10 um	low population density (long-term)	6.5960e-07
Particulates, > 2.5 um, and < 10um	low population density (long-term)	4.5352e-07
Particulates, < 2.5 um	low population density (long-term)	2.6443e-07
Sulfur dioxide	low population density (long-term)	4.3861e-08
Nitrogen oxides	low population density (long-term)	2.1007e-08
Nitrogen oxides	lower stratosphere + upper troposphere	2.1979e-09
Ammonia	low population density (long-term)	6.5822e-10
Ammonia	industrial	1.9079e-11
Sulfur dioxide	lower stratosphere + upper troposphere	1.4220e-11
Particulates, < 2.5 um	lower stratosphere + upper troposphere	2.8546e-12

3.3 SISTEMA 1 — FATORES DE CARACTERIZAÇÃO OBERSCHELP (2020)

Modelo de caracterização: Oberschelp et al. (2020). DOI: 10.1021/acs.est.0c05691
Modelo de efeito: `Average` ů **Altura**: `Ground level` ů **Tempo**: anual, dia-noite

Substância	Massa total emitida (kg / kg FPCM)	CF Global (DALY/kg)	CF Brasil (DALY/kg)	CF Estado-SP (DALY/kg)
Ammonia (NH3)	9.837e-04	2.004e-05	6.443e-05	5.125e-04
Nitrogen oxides (NOx)	5.315e-04	2.622e-06	8.877e-06	6.924e-05
Particulates, < 2.5 um (PM2.5)	1.279e-04	4.817e-05	8.620e-05	6.505e-04
Sulfur dioxide (SO2)	2.235e-04	4.608e-06	8.769e-06	5.902e-05

3.4 SISTEMA 2 — FATORES DE CARACTERIZAÇÃO OBERSCHELP (2020)

```
**Modelo de caracterização**: Oberschelp et al. (2020). DOI: 10.1021/acs.est.0c05691
**Modelo de efeito**: `Average` ů **Altura**: `Ground level` ů **Tempo**: anual,
    dia-noite

| Substância | Massa total emitida (kg / kg FPCM) | CF Global (DALY/kg) | CF Brasil
    (DALY/kg) | CF Estado-PR (DALY/kg) |
|---|---|---|---|---|
| Ammonia (NH3) | 3.052e-04 | 2.004e-05 | 3.152e-04 | 3.861e-04 |
| Nitrogen oxides (NOx) | 3.038e-04 | 2.622e-06 | 8.877e-06 | 2.687e-05 |
| Particulates, < 2.5 um (PM2.5) | 1.029e-04 | 4.817e-05 | 8.620e-05 | 2.419e-04 |
| Sulfur dioxide (SO2) | 2.045e-04 | 4.608e-06 | 8.769e-06 | 2.197e-05 |
```

4 RESULTADOS COMPLETOS DO EXPERIMENTO PRINCIPAL

4.1 MAPE POR (LLM × NÍVEL × IDIOMA × ESCOPO)

Table 2 – S1. Erro relativo absoluto médio (MAPE) por (LLM × nível × idioma × escopo geográfico) — Sistema 1.

LLM	Nivel / Idioma	Global	Brasil	Estado
GPT	L0 / pt-BR	+5.0×	+1.1×	+65%
GPT	L0 / en	+4.2×	+1.1×	+83%
GPT	L1 / pt-BR	+7.8×	+1.9×	+81%
GPT	L1 / en	—	—	—
GPT	L2 / pt-BR	—	—	—
GPT	L2 / en	—	—	—
GPT	L3 / pt-BR	+7%	+24%	+26%
GPT	L3 / en	+9%	+21%	+23%
GPT	L4 / pt-BR	+5%	+16%	+17%
GPT	L4 / en	+9%	+7%	+7%
Gemini	L0 / pt-BR	+8.3×	+3.2×	—
Gemini	L0 / en	+33.5×	+14.9×	+2.2×
Gemini	L1 / pt-BR	+351.5×	+175.5×	—
Gemini	L1 / en	+182.9×	+81.0×	+48%
Gemini	L2 / pt-BR	+3.9×	+1.3×	—
Gemini	L2 / en	+75%	+44%	+93%
Gemini	L3 / pt-BR	+3%	+4%	+4%
Gemini	L3 / en	+0%	+0%	+0%
Gemini	L4 / pt-BR	+0%	+0%	+0%
Gemini	L4 / en	+0%	+0%	+0%
DeepSeek	L0 / pt-BR	+4.3×	+1.5×	+61%
DeepSeek	L0 / en	+41.4×	+17.5×	+1.8×
DeepSeek	L1 / pt-BR	+179.2×	+77.5×	+11.6×
DeepSeek	L1 / en	+41.4×	+17.5×	+1.8×
DeepSeek	L2 / pt-BR	+4.3×	+85%	+76%
DeepSeek	L2 / en	+4345.7×	+1516.1×	+192.0×
DeepSeek	L3 / pt-BR	+20.7×	+16.4×	+15.8×
DeepSeek	L3 / en	+35%	+7%	+3%
DeepSeek	L4 / pt-BR	+19%	+19%	+21%
DeepSeek	L4 / en	+2%	+4%	+8%

Table 3 – S2. Erro relativo absoluto médio (MAPE) por (LLM × nível × idioma × escopo geográfico) — Sistema 2.

LLM	Nivel / Idioma	Global	Brasil	Estado
GPT	L0 / pt-BR	+15.4×	+10%	—
GPT	L0 / en	+18.5×	+1.6×	—
GPT	L1 / pt-BR	+16.5×	+93%	—
GPT	L1 / en	—	—	—
GPT	L2 / pt-BR	—	—	—
GPT	L2 / en	—	—	—
GPT	L3 / pt-BR	+49%	+2.1×	+1.7×
GPT	L3 / en	+69%	+41%	+13%
GPT	L4 / pt-BR	+20%	+76%	+54%
GPT	L4 / en	+17%	+55%	+35%
Gemini	L0 / pt-BR	+91.9×	+10.5×	—
Gemini	L0 / en	+128.5×	+15.5×	+12.5×
Gemini	L1 / pt-BR	+1611.0×	+7.9×	—
Gemini	L1 / en	+1330.3×	+213.3×	+9.4×
Gemini	L2 / pt-BR	+1.5×	+51%	—
Gemini	L2 / en	+3.7×	+75%	+21%
Gemini	L3 / pt-BR	+0%	+0%	+0%
Gemini	L3 / en	+0%	+0%	+0%
Gemini	L4 / pt-BR	+0%	+0%	+0%
Gemini	L4 / en	+0%	+0%	+0%
DeepSeek	L0 / pt-BR	+10.7×	+83%	+38%
DeepSeek	L0 / en	+92.7×	+12.7×	+10.6×
DeepSeek	L1 / pt-BR	+92.7×	+12.7×	+9.9×
DeepSeek	L1 / en	+116.1×	+17.3×	+15.1×
DeepSeek	L2 / pt-BR	+7494.7×	+875.5×	+617.1×
DeepSeek	L2 / en	+9599.9×	+1121.7×	+790.7×
DeepSeek	L3 / pt-BR	+1169.8×	+1167.3×	+1389.3×
DeepSeek	L3 / en	+62%	+20%	+50%
DeepSeek	L4 / pt-BR	+67%	+25%	+53%
DeepSeek	L4 / en	+38%	+17%	+52%

4.2 CURVAS DE SATURAÇÃO POR SISTEMA

4.3 DISTRIBUIÇÃO DA LOG-RAZÃO

4.4 COEFICIENTE DE VARIAÇÃO INTRA-CÉLULA

4.5 MODELO DE CARACTERIZAÇÃO DECLARADO PELOS LLMS

5 TESTE DE CONTAMINAÇÃO — DETALHADO

5.1 ESQUEMAS DE PERTURBAÇÃO

P1 (escala uniforme): todas as massas de emissão multiplicadas por 2,0. Novo *ground truth* esperado = 2× original.

P2 (amônia atenuada): massa de amônia (NH_3, precursor dominante para PM secundário) multiplicada por 0,1, demais inalteradas. Para o Sistema 1, novo GT

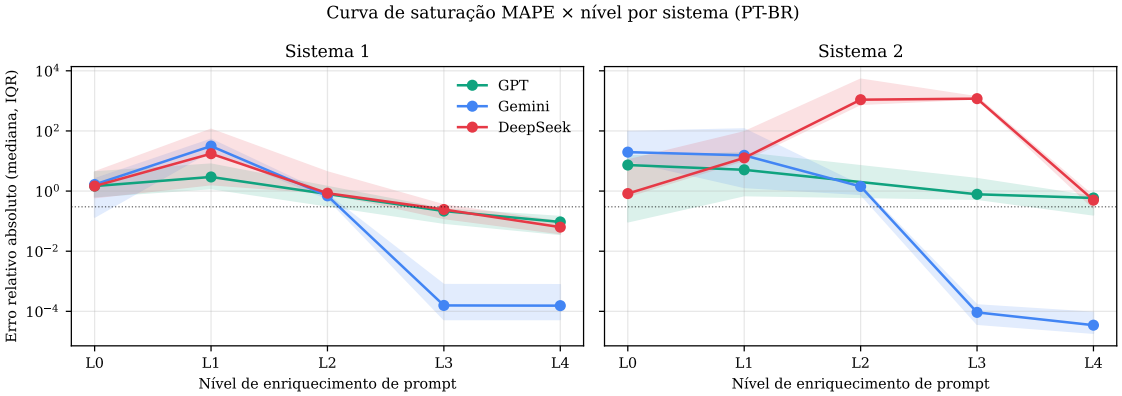


Figure 1 – Erro relativo absoluto (mediana, IQR) por nível de enriquecimento de prompt, separado por sistema (PT-BR). Eixo *y* em escala logarítmica.

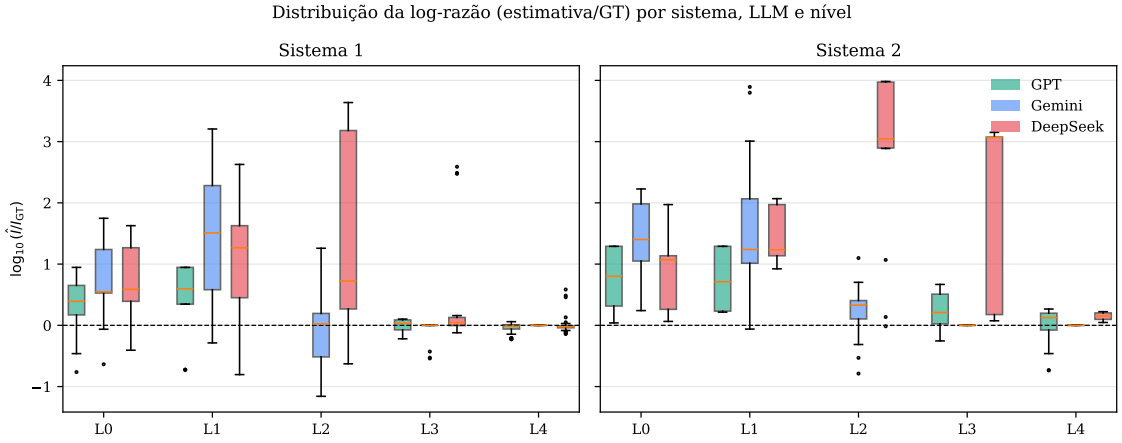


Figure 2 – Distribuição do $\log_{10}(\hat{I}/I_{\mathrm{GT}})$ por sistema, LLM e nível.

esperado $\approx 0{,}37\times$ original; para o Sistema 2, $\approx 0{,}57\times$.

P3 (perturbação aleatória): cada substância multiplicada por um fator aleatório $\sim$U[0,5; 2,0] com *seed* fixa (42), produzindo um novo GT determinístico mas sem padrão geométrico imediato.

Em todas as 180 chamadas do teste, o prompt inclui nota experimental explícita informando que o inventário é hipotético e instruindo cálculo estrito sobre os números fornecidos.

5.2 CLASSIFICAÇÃO POR (SISTEMA × LLM × ESQUEMA × NÍVEL)

5.3 RESPOSTA DO LLM VS. NOVO *GROUND TRUTH*

6 COMPARAÇÃO COM O PAPER-REFERÊNCIA

6.1 TABELA COMPARATIVA GIUSTI VS. LLMS

A Tabela 7 apresenta lado a lado o *ground truth* de GIUSTI *et al.* (2023) e as medianas das respostas dos três LLMs nos níveis L3 e L4 (PT-BR, $n = 10$ por célula). A Figura 5 apresenta a comparação visual em escala logarítmica.

Table 4 – Coeficiente de variação intra-célula (CV entre 5 repetições), média sobre 3 escopos geográficos.

Sis.	LLM	Nivel	CV (PT-BR)	CV (EN)
S1	GPT	L0	0.126	0.379
S1	GPT	L1	0.097	—
S1	GPT	L2	—	—
S1	GPT	L3	0.184	0.133
S1	GPT	L4	0.149	0.061
S1	Gemini	L0	1.504	0.409
S1	Gemini	L1	1.661	0.704
S1	Gemini	L2	1.449	0.236
S1	Gemini	L3	0.154	0.000
S1	Gemini	L4	0.000	0.000
S1	DeepSeek	L0	0.000	0.000
S1	DeepSeek	L1	1.110	0.000
S1	DeepSeek	L2	0.000	0.000
S1	DeepSeek	L3	3.984	0.021
S1	DeepSeek	L4	0.491	0.019
S2	GPT	L0	0.048	0.000
S2	GPT	L1	0.235	—
S2	GPT	L2	—	—
S2	GPT	L3	0.374	0.067
S2	GPT	L4	0.401	0.023
S2	Gemini	L0	0.483	0.606
S2	Gemini	L1	1.388	1.870
S2	Gemini	L2	0.271	0.928
S2	Gemini	L3	0.000	0.000
S2	Gemini	L4	0.000	0.000
S2	DeepSeek	L0	0.054	0.000
S2	DeepSeek	L1	0.039	0.000
S2	DeepSeek	L2	0.499	0.000
S2	DeepSeek	L3	0.023	0.004
S2	DeepSeek	L4	0.020	0.035

6.2 ANÁLISE DE SENSIBILIDADE AO LIMIAR DE CLASSIFICAÇÃO

A classificação *cálculo/memorização/misto* usa um limiar de $\pm 10\%$ contra os *ground truths*. A Tabela 8 mostra que o ordenamento das taxas e a magnitude da diferença entre Gemini, GPT e DeepSeek são robustos sob limiares de $\pm 5\%$ e $\pm 15\%$.

6.3 DECOMPOSIÇÃO DA MEMORIZAÇÃO POR PERTURBAÇÃO E POR NÍVEL

A Tabela 9 apresenta a contagem de chamadas classificadas como *memorização* estratificada por esquema de perturbação (P1, P2, P3) e por nível de prompt (L3, L4), revelando que o padrão é estável dentro de cada combinação LLM $\times$ sistema.

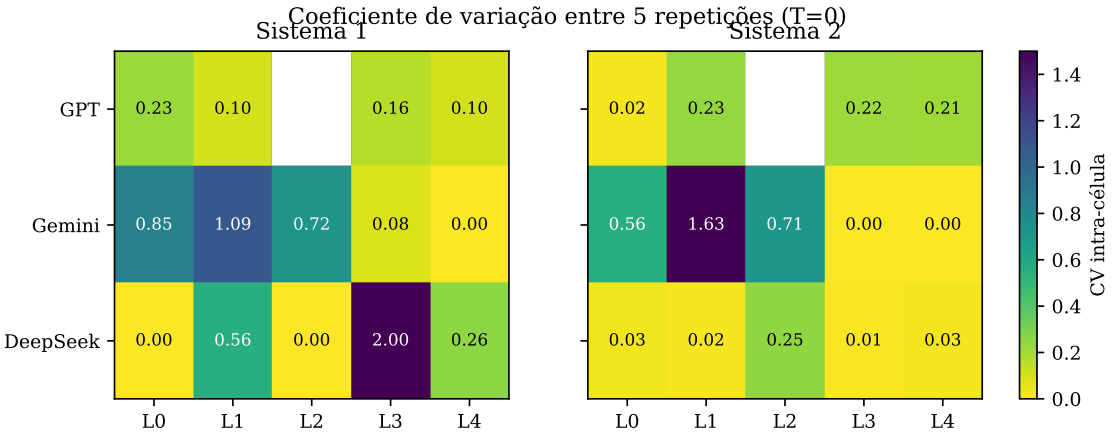


Figure 3 – Coeficiente de variação intra-célula entre 5 repetições sob $T = 0$, média sobre 3 escopos geográficos e 2 idiomas.

Table 5 – Modelo de caracterização declarado pelos LLMs por (sistema × nível). Conta-se PT-BR + EN.

Sis.	Nivel	Oberschelp	ReCiPe 2016	IMPACT World+	Outro	Não espec.
S1	L0	0	14	16	0	0
S1	L1	0	13	12	0	5
S1	L2	0	10	9	10	1
S1	L3	29	0	0	0	1
S1	L4	30	0	0	0	0
S2	L0	0	17	13	0	0
S2	L1	0	12	13	0	5
S2	L2	0	8	12	9	1
S2	L3	29	0	0	0	1
S2	L4	29	0	0	0	1

7 DIFERENCIAÇÃO REGIONAL

A razão *Estado/Global* esperada é 22,5× para o Sistema 1 e 12,1× para o Sistema 2. Em L0–L2, os três LLMs reportam razões de 1,0× a 3,0×, subestimando a diferenciação em uma a duas ordens de magnitude. A Tabela 10 apresenta as razões medianas por (sistema × LLM × nível).

8 REPRODUTIBILIDADE

8.1 REPOSITÓRIO PÚBLICO

Todo o pipeline experimental, dados brutos (JSONL com as 480 chamadas), prompts versionados, scripts de análise e código LaTeX são disponibilizados em:

`https://github.com/Roverlucas/ia-acv-gcv2026`

8.2 ESTRUTURA DO REPOSITÓRIO

`prompts/templates/` templates L0–L4 em PT-BR e EN, com instrução de sistema e esquema JSON.

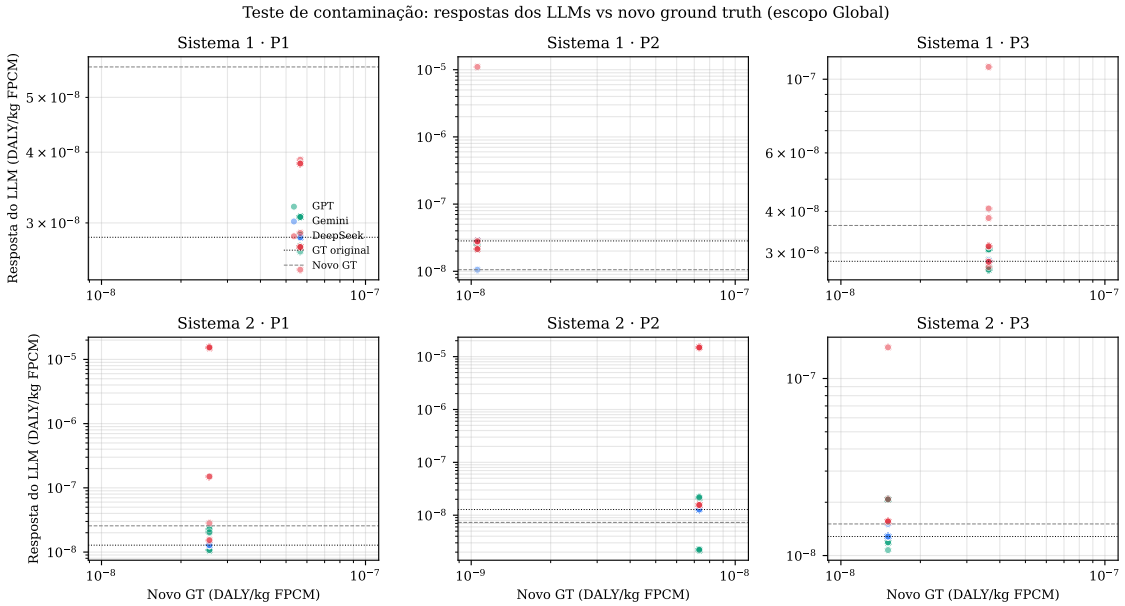


Figure 4 – Resposta do LLM (escopo Global) vs. novo *ground truth* calculado para cada esquema de perturbação. Linha pontilhada: GT original publicado. Linha tracejada: novo GT esperado caso o LLM tivesse calculado a partir do inventário perturbado.

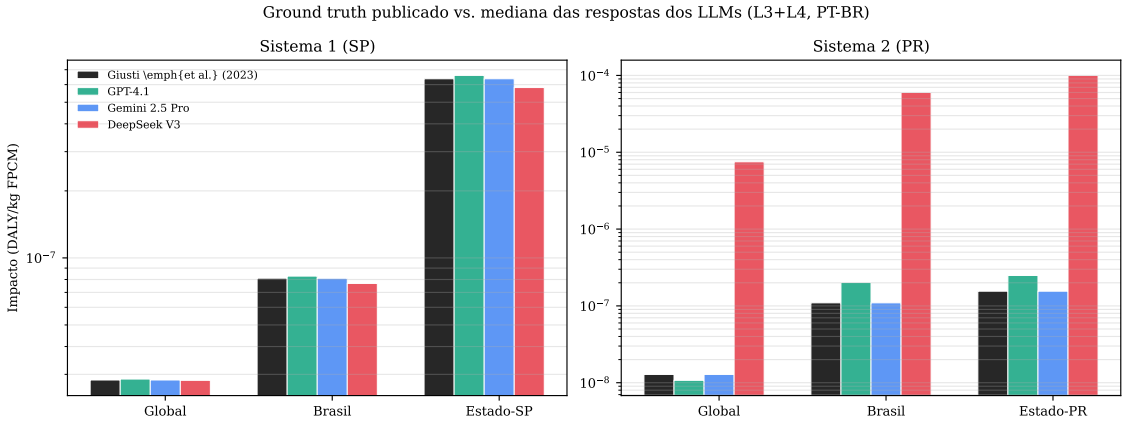


Figure 5 – Ground truth publicado vs. mediana das respostas dos LLMs em L3+L4 (PT-BR). Eixo *y* em escala logarítmica.

`prompts/runs/` *snapshot* dos prompts efetivamente executados (hash em SHA-256 truncado em 12 caracteres por arquivo).

`src/run_experiment.py`, `src/run_stress_test.py` orquestradores das 300 chamadas do experimento principal e 180 do teste de contaminação.

`src/analyze.py`, `src/analyze_regional.py`, `src/figures.py`, `src/generate_sm_ta` pipeline de análise e geração de artefatos.

`results/raw/*.jsonl` respostas brutas das LLMs (480 linhas no total, em 6 arquivos JSONL).

`data/processed/s{1,2}/` inventários agregados, fatores de caracterização e *ground truth* por sistema; inclui o subdiretório `stress/` com os inventários perturbados.

`manuscript/gcv2026/` resumo expandido e este material complementar em LaTeX.

8.3 CONFORMIDADE DE *SCHEMA* JSON

Das 480 chamadas registradas, 472 retornaram JSON conforme o esquema canônico em uma única tentativa; 8 falhas de *parsing* (todas em DeepSeek L4 EN) foram recuperáveis por avaliação aritmética das expressões fornecidas em vez de literais numéricos no campo `value`. Nenhuma chamada exigiu reexecução.

8.4 CUSTO AGREGADO

Experimento principal (300 chamadas): US$ 3,42, 108 minutos.

Teste de contaminação (180 chamadas): US$ 2,65, $\approx$ 90 minutos.

Total US$ 6,07, $\approx$ 200 minutos de execução.

8.5 CONFLITO DE INTERESSE

Uma das autoras (Yara de Souza Tadano) é coautora do paper-referência (Giusti *et al.*, 2023). Toda comparação foi feita contra os números publicados, sem reanálise privilegiada do dado bruto.

Table 6 – Classificação detalhada das 180 chamadas do teste de contaminação por (sistema × LLM × esquema × nível). Cada célula tem $n = 5$ chamadas.

Sis.	LLM	Esquema	Nivel	Cálc.	Mem.	Misto	Null
S1	GPT	P1	L3	0	5	0	0
S1	GPT	P1	L4	0	5	0	0
S1	GPT	P2	L3	0	5	0	0
S1	GPT	P2	L4	0	2	3	0
S1	GPT	P3	L3	0	5	0	0
S1	GPT	P3	L4	0	5	0	0
S1	Gemini	P1	L3	0	5	0	0
S1	Gemini	P1	L4	0	5	0	0
S1	Gemini	P2	L3	1	4	0	0
S1	Gemini	P2	L4	0	5	0	0
S1	Gemini	P3	L3	0	5	0	0
S1	Gemini	P3	L4	0	5	0	0
S1	DeepSeek	P1	L3	0	1	4	0
S1	DeepSeek	P1	L4	0	4	1	0
S1	DeepSeek	P2	L3	0	0	5	0
S1	DeepSeek	P2	L4	0	4	0	1
S1	DeepSeek	P3	L3	1	0	4	0
S1	DeepSeek	P3	L4	0	4	1	0
S2	GPT	P1	L3	0	0	5	0
S2	GPT	P1	L4	0	0	5	0
S2	GPT	P2	L3	0	0	5	0
S2	GPT	P2	L4	0	0	5	0
S2	GPT	P3	L3	0	3	2	0
S2	GPT	P3	L4	0	0	5	0
S2	Gemini	P1	L3	0	5	0	0
S2	Gemini	P1	L4	0	5	0	0
S2	Gemini	P2	L3	0	5	0	0
S2	Gemini	P2	L4	0	5	0	0
S2	Gemini	P3	L3	0	5	0	0
S2	Gemini	P3	L4	1	4	0	0
S2	DeepSeek	P1	L3	0	0	4	1
S2	DeepSeek	P1	L4	0	0	5	0
S2	DeepSeek	P2	L3	0	0	5	0
S2	DeepSeek	P2	L4	0	0	5	0
S2	DeepSeek	P3	L3	0	0	1	4
S2	DeepSeek	P3	L4	4	0	1	0

Table 7 – Comparação entre o *ground truth* de Giusti *et al.* (2023) e a mediana das respostas dos LLMs em L3+L4 (PT-BR, $n = 10$ por célula). Valores em DALY/kg FPCM.

Sistema	LLM / fonte	Global	Brasil	Estado
S1 (SP)	*Giusti et al. (2023)*	2.83×10^{-8}	8.11×10^{-8}	6.37×10^{-7}
	GPT-4.1	2.86×10^{-8}	8.29×10^{-8}	6.60×10^{-7}
	Gemini 2.5 Pro	2.83×10^{-8}	8.10×10^{-8}	6.37×10^{-7}
	DeepSeek V3	2.82×10^{-8}	7.68×10^{-8}	5.82×10^{-7}
S2 (PR)	*Giusti et al. (2023)*	1.28×10^{-8}	1.10×10^{-7}	1.55×10^{-7}
	GPT-4.1	1.07×10^{-8}	2.02×10^{-7}	2.49×10^{-7}
	Gemini 2.5 Pro	1.28×10^{-8}	1.10×10^{-7}	1.55×10^{-7}
	DeepSeek V3	7.51×10^{-6}	6.01×10^{-5}	1.00×10^{-4}

Table 8 – Sensibilidade da classificação à escolha do limiar (taxa de *memorização* em % para diferentes janelas).

		Sistema 1			Sistema 2		
LLM	n	5%	10%	15%	5%	10%	15%
GPT-4.1	30	43%	90%	100%	0%	10%	10%
Gemini 2.5 Pro	30	97%	97%	97%	97%	97%	97%
DeepSeek V3	30	45%	45%	59%	0%	0%	0%

Table 9 – Decomposição da taxa de *memorização* por perturbação e por nível (chamadas/5 por célula).

		L3			L4		
LLM	**Sis.**	P1	P2	P3	P1	P2	P3
GPT-4.1	S1	5/5	5/5	5/5	5/5	2/5	5/5
GPT-4.1	S2	0/5	0/5	3/5	0/5	0/5	0/5
Gemini 2.5 Pro	S1	5/5	4/5	5/5	5/5	5/5	5/5
Gemini 2.5 Pro	S2	5/5	5/5	5/5	5/5	5/5	4/5
DeepSeek V3	S1	1/5	0/5	0/5	4/5	4/5	4/5
DeepSeek V3	S2	0/5	0/5	0/5	0/5	0/5	0/5

Table 10 – Razão mediana *Estado/Global* reportada pelos LLMs vs. *ground truth* publicado.

Sis.	LLM	L0	L1	L2	L3	L4	GT publicado
S1	GPT	1.47	0.48	—	21.65	22.41	22.52
S1	Gemini	1.87	3.05	1.13	22.52	22.52	22.52
S1	DeepSeek	1.58	1.50	1.00	17.45	20.21	22.52
S2	GPT	—	—	—	15.79	19.78	12.13
S2	Gemini	1.23	1.08	1.17	12.13	12.13	12.13
S2	DeepSeek	1.50	1.58	1.00	13.33	11.96	12.13